

AI Daily Academy

day 002 2026-08-14

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

Week 1「AIの全体像」

Day 2「トークンとコンテキスト」

1. オープニング

おはようございます。AI Daily Academy、Week 1、Day 2です。

今日のテーマは、「トークンとコンテキスト」。

昨日は、生成AIとLLM、つまり大規模言語モデルの全体像を学びました。今日はその続きとして、AIが文章をどう受け取り、どこまで覚えながら会話できるのかを理解していきます。

生成AIに依頼したのに、途中から話を忘れたような答えが返ってきた。長い資料を渡したら、要約が雑になった。あるいは、同じ内容なのに日本語と英語で料金や反応速度が違う気がする。そんな経験があるかもしれません。

その背景には、多くの場合、「トークン」と「コンテキスト」があります。

今日のゴールはシンプルです。

トークンを、AIが文章を扱うための小さな単位として理解すること。

コンテキストを、AIがその瞬間に参照できる作業機の広さとして理解すること。

そして、実務でAIにより良い仕事をしてもらうために、情報をどう渡せばいいかを身につけることです。

通勤中ですので、難しい数式は使いません。

身近な例と仕事の例を中心に、耳でわかる形で進めていきましょう。

2. 前回の復習

まず、昨日の復習です。

生成AIは、文章、画像、音声、コードなどを新しく作り出すAIです。

その中でもLLM、大規模言語モデルは、大量の文章を学習し、次に続く可能性が高い言葉を予測しながら文章を生成します。

ここで大事なのは、LLMは人間のように、頭の中に固定された文章を丸ごと取り出しているわけではない、ということです。

AIは入力された指示や会話の流れを手がかりにして、次に来る言葉、さらにその次の言葉を、一つずつ予測します。

その連続によって、会話、要約、企画書、メール、プログラムなどが生まれます。

昨日、AIへの依頼では、「何をしてほしいか」「誰向けか」「どんな形式か」「何を避けるか」を具体的にするほど、出力の品質が安定しやすい、とお伝えしました。

今日はそこに、もう一つ重要な視点を足します。

それが、AIに渡す情報量です。

どれほど良い指示でも、必要な資料がAIの見える範囲に入っていないければ、正確には答えられません。

反対に、関係のない情報を大量に渡せば、本当に大切な部分が埋もれることがあります。

この「AIに見える範囲」を考えるための基本語が、トークンとコンテキストです。

3. 今日の基礎講義

では、トークンから始めましょう。

トークンとは、AIが文字や言葉を処理するときの、細かい区切りです。

日本語でいう「単語」と完全に同じではありません。

たとえば、人間が「生成AI」という言葉を見ると、一つの専門用語として理解できます。

しかしAIの内部では、「生成」と「AI」に近いまとまりになるかもしれませんし、別の分かれ方をするかもしれません。

英語でも同じです。

短い単語なら一つのトークンになる場合がありますが、長い単語、珍しい単語、固有名詞、記号を含む文字列などは、複数のトークンに分かれます。

つまり、トークンは、人間にとっての文字数でも、単語数でもありません。

AIにとっての処理上の部品です。

ここで、実務的に大切な考え方を一つ。

「何文字まで入力できますか」という質問は、正確には「何トークンまで扱えますか」という話になります。

日本語では、ひらがな、漢字、カタカナ、英数字、記号の組み合わせ方によって、同じ文字数でもトークン数が変わります。

そのため、「日本語千文字なら必ず何トークン」と断言することはできません。

ただし、感覚としては、文章が長くなればトークンも増える。

そして、入力する文章だけでなく、AIが返す文章にもトークンが使われる。

この二点を押さえておけば、最初は十分です。

次に、コンテキストです。

コンテキストとは、AIが一回の応答を作る時点で、参照できる情報の範囲です。

「文脈」と訳されることもあります。

イメージしてみましょう。

あなたが机に向かって、会議資料を読みながらメールを書いているとします。机が広ければ、議事録、顧客情報、過去のメール、見積もり、社内ルールを全部並べて確認できます。

しかし机が小さければ、古い資料をいったん脇にどけなければ、新しい資料を広げられません。

AIのコンテキストも、これに近いものです。

AIが今見ているのは、基本的には、その会話で渡された指示、過去のやり取り、添付資料、必要に応じて取得した外部情報、そしてこれから生成する回答のための余地です。

重要なのは、コンテキストには上限があることです。

この上限を、コンテキストウィンドウ、あるいは文脈長と呼びます。

たとえば長い会話を続けたとき、最初の方で伝えた条件が反映されなくなることがあります。

これはAIが怠けたというより、初期の会話が参照範囲の外に出た、あるいは長い情報の中で重要度が下がった可能性があります。

さらに、コンテキストの上限は、入力だけの上限ではありません。

入力と出力を合計した上限として設計されている場合があります。

長い契約書を渡し、「一万字で詳細にレビューして」と依頼した場合を考えてみましょう。

契約書そのものが大きなトークン数を使い、さらに回答にもトークンが必要です。

入力が上限ぎりぎりなら、AIが長い回答を作る余地は少なくなります。

つまり、AIに長い資料を渡すときは、資料を全部入れられるかだけでなく、「回答のための席を残せているか」も考える必要があります。

ここまでを一言でまとめると、こうです。

トークンは、AIが文章を数える単位。

コンテキストは、そのトークンを使ってAIが今見渡せる作業範囲。

この二つがわかると、AIとの会話で起きる不思議な現象の多くを説明できます。

4. 仕組み・応用

では、もう少し仕組みに近づいてみましょう。

LLMは、与えられたコンテキストの中から、次にどのトークンを出すのがもっとも自然か、あるいは指示に合うかを計算します。

たとえば、あなたがこう依頼したとします。

「以下の会議メモをもとに、部長向けに三点で要約してください。」

AIは、まずこの依頼文をトークンとして受け取ります。

続いて会議メモをトークンとして受け取ります。

そして、「部長向け」「三点」「要約」という条件を保ちながら、出力するトークンを順番に選びます。

ここでAIは、会議メモのすべてを人間のように完全理解して、頭の中に長期保存しているわけではありません。

その時点で与えられた情報の関係を計算しながら、出力を組み立てています。

このため、コンテキスト内に重要な数字が書いてあっても、資料が長すぎたり、似た情報が多すぎたりすると、AIが見落とす可能性はあります。

「コンテキストに入れたから、必ず正確」とは言い切れません。

ここは実務で非常に大切です。

コンテキストを増やせば、AIが読める資料は増えます。

しかし、資料が多ければ多いほど常に品質が上がる、というわけではありません。

たとえば、営業提案書を作るために、過去五年分の全資料を一度に投入したとします。

AIは参照できる情報が増える一方で、古い価格表、現在は使わない商品名、別の顧客向けのルールなども混ざります。

その結果、もっともらしいけれど古い内容を採用してしまうかもしれません。

そこで必要になるのが、情報の選別です。

AIに渡すべきなのは、「多い情報」ではなく、「今の仕事に必要で、信頼でき、優先順位が明確な情報」です。

この考え方は、RAG、ラグと呼ばれる仕組みにもつながります。

RAGは、AIが答える前に、社内文書やデータベースから関連する情報を検索し、その検索結果をコンテキストとして渡す方法です。

たとえば、社内規程について質問されたとき、モデルの学習知識だけに頼るのではなく、最新版の社内規程から関係する数段落を取り出して渡す。

その内容を根拠に回答させる。

これがRAGの基本的な発想です。

ここでのポイントは、「社内文書を全部AIに記憶させる」ことではありません。

質問に応じて、必要な情報を、その都度、作業机に載せることです。

そして、このときもトークンが関わります。

検索結果を何十件も全部入れると、重要な規程が埋もれます。

反対に、検索結果が少なすぎると根拠が不足します。

ですからRAGでは、検索の精度、資料の更新管理、引用元の明示、回答後の人間による確認が重要になります。

もう一つ、実務で知っておきたいのが、トークンとコスト、速度の関係です。

一般に、AIサービスのAPI、つまりシステムからAIを呼び出す仕組みでは、入力トークンと出力トークンの量が料金に関係します。

長い入力、長い出力、何度も同じ資料を送る設計は、コストと応答時間を増やす要因になります。

もちろん、短くすればよいわけではありません。

必要な条件まで削ると、出力品質が下がります。

目指すべきは、最短の指示ではなく、必要十分な指示です。

たとえば、「メールを書いて」だけでは情報不足です。

一方で、相手の過去十年分のメールをすべて貼る必要も通常はありません。

「取引先の担当者へ。納期が二日遅れるお詫び。理由は部材調達の遅れ。代替案として一部先行納品。丁寧だが過度に言い訳しない。二百字程度。」

この程度まで整理されていれば、AIが使うコンテキストは小さくても、品質は上がりやすくなります。

5. 身近な具体例

ここからは、日常の例で考えてみましょう。

一つ目は、旅行計画です。

あなたがAIに、「来月、家族三人で二泊三日の旅行プランを考えて」と頼むとします。

これだけでも案は出ますが、AIにとっては条件が曖昧です。

出発地、予算、子どもの年齢、移動手段、食べられないもの、雨天の場合、朝が早いのは苦手か、観光中心か休養中心か。

こうした条件がコンテキストです。

必要な条件を少しずつ加えることで、AIの作業机に判断材料が増え、提案の精度が上がります。

ただし、旅行先の営業時間、運行状況、料金、天気などは変わります。

AIがもっともらしく答えても、最新情報として使うなら、公式サイトや予約サイトで確認しなければなりません。

二つ目は、料理です。

冷蔵庫の中身をAIに伝えて、献立を作ってもらう場면을想像してください。

「卵、キャベツ、豚こま、豆腐があります。二人分、二十分以内、辛いもの」と伝える。

これは、AIに渡す小さくて質の高いコンテキストです。

ここで、アレルギー情報があるなら最優先で伝える必要があります。

「甲殻類アレルギーあり。調味料も含めて避ける」と明示する。

大事な条件は、長い文章の途中で埋めず、最初か最後に箇条書きで置くとよいでしょう。

三つ目は、学習です。

長い講義ノートにAIを渡して、「要約して」と頼んだ場合、出てくる要約が浅いと感じることがあります。

そんなときは、一度に全部を要約させるより、段階を分けるのが有効です。

まず、「章ごとに重要な主張、根拠、専門用語を抽出してください」と頼む。

次に、「その抽出結果だけを使って、初心者向けに五分で説明する原稿を作って」と頼む。

最後に、「理解チェック問題を三問作って」と頼む。

このように、長い情報を小さな処理単位に分けることを、チャンク化と呼ぶことがあります。

AIに任せる仕事を分解し、各段階で結果を確認する。

これが、長い文書を扱うときの基本戦略です。

6. 実務での実用例

次に、仕事での使い方です。

まず、会議の要約です。

会議録をそのままAIに渡す前に、目的を一行で追加してください。

たとえば、

「この会議録から、経営会議向けに、決定事項、未決事項、担当者と期限、リスクを抽出してください。」

これだけで、AIが何を優先すべきかが明確になります。

さらに、出力形式も指定します。

「決定事項は三項目以内。担当者が不明なものは推測せず、不明と書く。数字は原文を引用して確認可能にする。」

このように書くと、AIが曖昧な部分を勝手に補うリスクを減らせます。

次に、顧客対応です。

問い合わせメールと、社内の回答方針をAIに渡して返信案を作る場合、入力情報を分けると管理しやすくなります。

一つ目、顧客の問い合わせ。

二つ目、事実として確定している回答。

三つ目、言ってはいけないこと。

四つ目、文体や長さ。

ここで特に注意したいのは、顧客情報や機密情報です。

利用するAIサービスの契約、設定、データ利用方針を確認し、社内ルールに従ってください。

個人情報や未公開情報を、許可なく外部サービスへ入力しないことが原則です。

三つ目は、企画書づくりです。

企画書をAIに作らせる場合、最初から「完成版を書いて」と頼むよりも、三段階に分けると安定します。

第一段階。

背景、課題、対象顧客、制約条件を渡して、論点を整理させる。

第二段階。

複数の企画案を出させ、それぞれのメリット、懸念、必要な検証を比較させる。

第三段階。

人間が選んだ案について、指定した構成で文章化させる。

これはコンテキスト管理でもあります。

最初から大量の資料と完成イメージを一度に渡すのではなく、今必要な判断に絞ってAIを使う方法です。

四つ目は、社内ナレッジ検索です。

「経費精算のルールは？」という質問に答えるAIを作る場合、最初に考えるべきはモデルの賢さだけではありません。

どの規程を正しい情報源とするか。更新日はいつか。古い規程をどう除外するか。回答に根拠を表示できるか。回答できないときに、どこへ案内するか。

この設計が重要です。

AIは、コンテキストに入った情報をもとに、自然な文章を作れます。

しかし、社内規程の正しさや最新版であることを、自動的に保証してくれるわけではありません。

だからこそ、業務で使うAIでは、「答えを作る仕組み」だけでなく、「正しい根拠を渡す仕組み」が価値になります。

7. 実装例

ここでは、社内規程を答えるシンプルなAIアシスタントを例に、実装の考え方を見てみましょう。

利用者が、「出張のホテル代の上限はいくらですか」と質問したとします。

最初に、システムは質問文を受け取ります。

次に、社内規程の検索システムが、出張規程の中からホテル代に関係する箇所を探します。

このとき、検索結果として渡すのは、規程全体ではありません。

たとえば、宿泊費の上限、地域区分、例外申請の条件、改定日が書かれた数段落です。

次にAIへ、次のような役割を与えます。

「あなたは社内規程案内アシスタントです。提供された根拠だけを使って教えてください。根拠にないことは推測せず、不明と教えてください。規程名と改定日を添えてください。」

そして、利用者の質問と、検索した規程の抜粋を一緒に渡します。

AIは、その限定されたコンテキストの中で回答を作ります。

回答例はこうです。

「国内出張の宿泊費上限は、東京二十三区内では一泊一万二千元です。ただし、繁忙期などで上限を超える場合は、事前承認が必要です。根拠は出張旅費規程、二〇二六年四月改定版です。」

ここでの要点は四つあります。

一つ。検索する資料は最新版に限定する。

二つ。AIに渡す資料は関連部分に絞る。

三つ。根拠にないことを推測させない。

四つ。回答には根拠と更新日を付ける。

もし検索結果が見つからなければ、AIに無理に答えさせないことも重要です。

「該当する規程を確認できませんでした。総務部の窓口、または最新の出張旅費規程を確認してください。」

このように、答えない設計も品質の一部です。

さらに、実装時にはトークン予算を決めます。

質問、システム指示、検索結果、回答のそれぞれに、どのくらいの情報量を割り当てるかを考えます。

検索結果が長すぎる場合は、関連度の高い順に絞る。

規程が複数ある場合は、最新日付を優先する。

回答が長くなりすぎないように、文字数や箇条書き数を指定する。

こうした工夫は、コスト削減だけではありません。

AIが重要な根拠に集中しやすくなるため、回答の読みやすさと再現性も上がります。

8. 今日のAI最新情報

ここからは、2026年8月14日時点のAI最新情報です。

ここで紹介するのは、今日、8月14日に発表されたニュースではなく、直近数週間に各社が公式発表した内容です。発表日を明確にしながら、今日のテーマであるトークンとコンテキストとの関係も見ていきます。

一つ目。Googleは8月13日、Gemini 3.7 Flashを発表しました。Googleは、コーディングやエージェント利用向けの高性能かつ比較的低コストなモデルとして位置づけています。発表では、入力トークン百万件あたりと出力トークン百万件あたりの価格も示されており、トークンが単なる技術用語ではなく、AIを業務に組み込む際の費用設計に直結することがわかります。大量の資料を処理する、あるいはエージェントが何度もツールを呼び出す場面では、入力と出力のトークン量を把握する重要性が増しています。([blog.google](https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-gemini-3-7-flash/))

二つ目。OpenAIは8月11日、日本を含む複数市場で、ChatGPT内の広告提供を開始したと更新しました。OpenAIは、広告が回答内容に影響しないこと、広告主には会話内容や個人情報を提供しないことを方針として説明しています。今日のテーマとの関係では、会話のコンテキストが、ユーザーにとって非常に個人的で価値のある情報になり得る点に注目です。AIを使う側としては、便利さだけでなく、どの情報を会話に入れるか、サービスがその情報をどう扱う設定なのかを理解する姿勢がますます重要です。([openai.com](https://openai.com/index/testing-ads-in-chatgpt/))

三つ目。Anthropicは8月7日、Claude Fable 5の生物学分野における安全策を更新したと発表しました。通常の教育や健康に関する質問で、より能力の低いモデルへ切り替わるケースを減らしつつ、悪用につながり得る領域では制限を維持する方針です。これは、AIが単に多くのコンテキストを扱えばよいわけではないことを示す例です。質問の内容、利用目的、危険性によって、どの情報を出し、どこで回答を制限するかという設計も、AIの実用性を左右します。([anthropic.com](https://www.anthropic.com/news/improving-fable-5-s-biology-safeguards))

四つ目。Googleは7月23日、AIが仕事や日常生活でどのように使われているかを調べるATLASという調査を公表しました。Googleの説明によれば、職場でのAI利用は幅広い一方、完全自動化よりも、情報整理、アイデア出し、学習、検索支援など、人間との協働に使われる割合が大きいとされています。これは今日の学びとも一致します。AIに仕事を丸投げするより、人間が目的と根拠を選び、必要なコンテキストを渡し、出力を確認する。その使い方が、現時点ではもっとも現実的で価値を出しやすい方法だと言えそうです。([blog.google](https://blog.google/innovation-and-ai/technology/research/understanding-the-ai-economy/))

最新情報からのまとめです。

AIモデルは高性能化し、長い情報や複雑な作業を扱えるようになっていきます。

同時に、トークンの費用、会話データの扱い、安全な情報提供、根拠の確認といった、使い方の設計がますます重要になっています。

9. 今日の要点整理

今日の要点を、七つにまとめます。

一つ目。

トークンは、AIが文章を扱うための細かい単位です。文字数や単語数と完全には一致しません。

二つ目。

コンテキストは、AIがその瞬間に参照できる情報の範囲です。作業機の広さだと考えるとわかりやすいでしょう。

三つ目。

コンテキストには上限があります。長い会話や資料では、古い情報が参照されにくくなったり、重要な情報が埋もれたりします。

四つ目。

入力だけでなく、出力にもトークンの余地が必要です。長い資料を渡すなら、回答のための席も残す必要があります。

五つ目。

情報は多ければよいではありません。目的に合った、信頼できる、最新の情報を絞って渡すことが大切です。

六つ目。

長い資料は、分割して処理し、段階的に要約、比較、文章化すると品質を管理しやすくなります。

七つ目。

業務利用では、AIに答えを作らせるだけでなく、正しい根拠を検索し、引用し、必要なら答えないように設計することが重要です。

今日から使える一つの習慣を挙げるなら、AIへ依頼する前に、こう自問してください。

「このAIに、本当に必要な情報だけを、優先順位がわかる形で渡せているだろうか。」

この問いが、AIの回答品質を大きく変えます。

10. 1分理解チェック

では最後に、一分理解チェックです。

答えは少し間を置いてからお伝えします。

第一問。

トークンは、人間にとっての文字数と必ず同じでしょうか。

……答えは、いいえ。

トークンはAIの処理単位であり、文字数や単語数とは完全には一致しません。

第二問。

コンテキストとは何でしょうか。

……答えは、AIがその時点で参照できる情報の範囲です。

会話履歴、指示、添付資料、検索結果などが含まれます。

第三問。

長い資料をAIに渡すとき、資料をできるだけ全部入れれば、必ず品質は上がるでしょうか。

……答えは、いいえ。

情報が多すぎると重要な内容が埋もれたり、古い情報や無関係な情報が混ざったりします。関連する根拠に絞ることが大切です。

第四問。

社内規程を答えるAIで、もっとも望ましい設計はどれでしょうか。

A、見つからない内容でも自然な回答を作る。

B、最新版の関連規程を検索して根拠として渡し、根拠がない場合は不明と答える。

……答えは、Bです。

自然さより、根拠、更新日、確認可能性を優先します。

第五問。

AIへの依頼を改善するため、まず意識したいことは何でしょうか。

……答えは、目的に必要な情報を、優先順位がわかる形で渡すことです。

お疲れさまでした。

11. 次回予告

次回、Day 3のテーマは、「プロンプトの基本」です。

今日学んだトークンとコンテキストを踏まえて、AIに何を、どの順番で、どのように伝えれば、回答の精度が上がるのかを扱います。

曖昧な依頼を、仕事で使える依頼へ変える。

出力形式を指定する。

AIに役割を与える。

そして、誤りや曖昧さを減らす聞き方を身につける。

明日からすぐ使える、実践的な内容です。

それでは、AI Daily Academy、Day 2を終わります。

今日もよい一日をお過ごしください。

参考情報・一次情報

1. タイトル: Introducing Gemini 3.7 Flash

発行元: Google

発表日: 2026-08-13

URL:

<https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-gemini-3-7-flash/>

2. タイトル: Testing ads in ChatGPT

発行元: OpenAI

発表日: 2026-08-11 (ページの更新日)

URL:

<https://openai.com/index/testing-ads-in-chatgpt/>

3. タイトル: Improving Fable 5 ' s biology safeguards

発行元: Anthropic

発表日: 2026-08-07

URL:

<https://www.anthropic.com/news/improving-fable-5-s-biology-safeguards>

4. タイトル: Understanding the AI economy

発行元: Google

発表日: 2026-07-23

URL:

<https://blog.google/innovation-and-ai/technology/research/understanding-the-ai-economy/>