

AI Daily Academy

day 004 2026-08-16

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

AI Daily Academy、Week 1「AIの全体像」。Day 4のテーマは、「学習と推論」です。

おはようございます。あるいは、こんにちは。通勤や移動の途中で聞いてくださっている方も多いでしょう。今日も、難しい式は使わずに、AIがどのように能力を身につけ、私たちの質問にどう答えているのかを、順番にひもといしていきます。

今日のキーワードは二つです。

****学習****。英語ではトレーニング。

そして、****推論****。英語ではインファレンスです。

この二つを区別できるようになると、「AIに何を任せられるのか」「AIがなぜ間違えるのか」「会社でAIを使うなら、どこにデータをつなげるべきか」が、ぐっと見通しやすくなります。

まず、前回の復習です。

Day 1では、生成AIとLLM、大規模言語モデルについて学びました。LLMは、大量の文章をもとに、次に続きそうな言葉を予測して文章を作るAIでした。会話、要約、翻訳、企画、プログラミングなどに使えるのは、この「次の言葉を予測する」能力が、非常に大きな規模で鍛えられているからです。

Day 2では、トークンとコンテキストを取り上げました。AIは文章を人間と同じように一文字ずつ読んでいるのではなく、トークンという細かな単位に分けて扱います。そして、会話の中でAIが一時的に参照できる範囲がコンテキストでした。つまり、長い会話で前の話を覚えているように見えても、それは多くの場合、会話の内容がコンテキストとして入力に含まれているからです。

Day 3では、Embedding、つまり埋め込み表現とベクトルを学びました。文章や画像の意味を、数字の並びに変換する技術です。意味が近いものほど、ベクトル空間の中でも近くに置かれます。社内文書から質問に近い資料を探すRAG、商品推薦、重複文書の検出などで活躍します。

ここまでを一言でつなぐと、こうです。

LLMは、トークンを受け取り、コンテキストを参考にしながら、次のトークンを予測します。Embeddingは、必要な情報を意味で探して、LLMに渡すための技術です。

そして今日学ぶ学習と推論は、そのLLMが、そもそもどう作られ、実際の利用時にどう動くのかを説明する、二本柱です。

では、今日の基礎講義に入りましょう。

最初に、もっとも大切な結論をお伝えします。

学習とは、AIの内部にある大量の調整つまみを、データをもとに変える工程です。

推論とは、調整済みのAIに入力を渡し、答えを計算させる工程です。

たとえば、料理にたとえてみましょう。

学習は、料理人が何千、何万回も料理を作り、味見をして、火加減、塩、砂糖、だしの量を調整しながら、レシピを身につける時間です。

一方の推論は、その料理人が身につけたレシピを使い、注文を受けて実際に料理を作る時間です。

AIに「会議メモを要約して」と頼むとき、あなたが使っているのは推論です。その会議メモを読んだ瞬間に、AIが根本から賢くなっているわけではありません。すでに学習済みの能力を使って、今の入力に対する答えを計算しているのです。

この違いは、AI活用でとても重要です。

「AIにうちの会社のルールを覚えさせたい」と考えたとき、その方法は一つではありません。モデルそのものを追加学習するのか。必要なときだけ社内文書を検索して読ませるのか。会話の指示として毎回与えるのか。目的により、選ぶ方法が変わります。

では、学習の中身をもう少し見ていきましょう。

AIモデルの中には、**パラメータ**、あるいは重みと呼ばれる、非常に多くの数値があります。これが先ほどの「調整つまみ」です。

たとえば、「今日は雨です」という文章を見たAIが、「傘」という言葉を続きとして予測できるようになるまでを考えてみます。

最初のAIは、適当な予測しかできないかもしれません。「今日は雨です」の次に「机」や「宇宙」と予測してしまうかもしれません。しかし、大量の文章に触れながら、「雨」という言葉の近くには「傘」「天気」「濡れる」「降水確率」といった言葉が出やすいと、少しずつ学びます。

予測が外れたら、内部の数値をほんの少し調整します。次に同じような文章を見たとき、正しい続きを出しやすくなる方向に、つまみを動かします。

この「予測する、答えと比べる、ずれを小さくするように数値を直す」という繰り返しが、機械学習の基本です。

このとき、AIの予測と正解のずれを数値にしたものを、**損失、ロス**と呼びます。ロスが小さいほど、学習用データに対しては予測がうまくいっている、という意味です。

たとえば、穴埋め問題を解く練習帳を想像してください。

「日本の首都は、____です。」

正解は「東京」です。AIが「大阪」と答えたら、間違いです。この間違いの度合いを数値化し、次には「東京」を選びやすくなるよう、内部のパラメータを少し修正します。

もちろん現実のLLMは、こんな単純な一問一答をしているわけではありません。膨大な文章、コード、数式、画像の説明文などを使い、非常に多くのパラメータを同時に調整しています。しかし、根っこにある考え方は同じです。間違いから、少しずつ調整する。これが学習です。

ここで、もう一つ重要な言葉を紹介します。**勾配降下法、こうばいこうかほう**です。

難しく聞こえるかもしれませんが、イメージだけつかめば十分です。

霧が深い山の斜面で、一番低い場所を目指して少しずつ歩く場面を想像してください。足元の傾きを確認めて、下り坂の方向へ少し進む。進んだ先でまた傾きを確認め、さらに下りそうな方向へ進む。この繰り返しで谷底に近づいていきます。

AIは、損失を小さくする方向を計算しながら、内部の重みを少しずつ更新します。これが勾配降下法の直感的なイメージです。

ただし、学習で大事なものは、単に練習問題を丸暗記することではありません。

もし、過去問だけを完璧に暗記して、問題文の順番まで覚えてしまったら、新しい問題に対応できないかもしれません。AIにも同じことが起こります。これを**過学習**と呼びます。

学習用データには強いのに、初めて見るデータでは急に成績が悪くなる状態です。

だからAI開発では、学習に使うデータと、出来栄えを確認するためのデータを分けます。未知の問題にも対応できるかを確認するわけです。これは、学校でいうなら、授業中に使った問題集と、初見の模擬試験を分けるようなものです。

ここまでの、AIが能力を身につける「学習」の話です。

次に、利用時の「推論」を見ていきましょう。

あなたがチャットAIに、「来週の営業会議のアジェンダ案を、30分版で作って」と入力したとします。

AIは、入力文をトークンに分けます。次に、そのトークンと会話履歴、システム上の指示、必要なら検索結果や添付資料をコンテキストとして読み込みます。そして、「次に出すべきトークンは何か」を確率で計算します。

ここでAIは、答えを辞書からそのまま取り出しているわけではありません。内部のパラメータと、今渡されたコンテキストを使い、その場で次のトークンの候補を計算しています。

たとえば、最初に「以下」と出す確率が高い。続いて「の」、その次に「構成」、というように、少しずつ文章を生成します。この一歩ずつの生成を、**自己回帰的生成**と呼ぶことがあります。難しい言葉ですが、「自分が直前に出した言葉も次の判断材料にしながら、順番に文章を続ける」と理解すれば大丈夫です。

推論では、速度とコストが重要になります。

学習は、多くの場合、巨大な計算設備を長時間使う、大がかりな作業です。いっぽう推論は、ユーザーが使うたびに発生します。数百万人が同時に使えば、その回数分だけ計算が必要です。

そのため実務では、「最も賢いモデルを常に使う」だけが正解ではありません。

単純な分類や短い要約には、速くて安価なモデル。複雑な契約書の比較、設計レビュー、難しいプログラミングには、より強力な推論時間を多く使うモデル。こうした使い分けが重要になります。

AIサービスで見かける「高精度モード」「深く考えるモード」「高速モード」といった選択肢は、多くの場合、推論に使う計算量や時間、モデルの種類を調整する仕組みだと考えると分かりやすいでしょう。

ただし、注意点があります。

AIが長く考えたように見えるからといって、必ず正しいとは限りません。推論は、もっともらしい文章を作る計算でもあります。入力資料に誤りがあれば、その誤りを踏まえた答えを出す可能性があります。また、情報が足りなければ、空白をもっともらしく埋めてしまう、いわゆるハルシネーションも起こり得ます。

したがって、推論の結果は、目的に応じて検証する必要があります。特に法務、医療、金融、採用評価、契約、顧客への公式回答など、間違いの影響が大きい仕事では、人が最終責任を持つ設計が欠かせません。

では、学習と推論を、Day 3のEmbedding、ベクトルとつなげてみましょう。

ここでよく混同されるのが、**追加学習**と**RAG**です。

追加学習は、モデルのパラメータそのものを変えることです。つまり、学習です。

一方、RAGは、質問に関係する文書をベクトル検索などで探し、その文書をコンテキストとしてAIに渡してから答えを作らせる方法です。こちらは基本的に、推論時の工夫です。

たとえば、社内の就業規則について質問に答えるAIを作るとします。

「有給休暇の繰越上限は？」という質問に対し、就業規則の該当箇所を検索し、その部分をAIに読ませて答えさせる。これはRAGです。規則が改定されたら、文書を差し替え、Embeddingを作り直して検索対象を更新すればよい場合があります。モデル自体を再学習する必要はありません。

一方で、会社独自の文章の書き方、たとえば決まった帳票形式や、専門的な分類ルール、特定の操作手順を安定して再現させたい場合には、追加学習が候補になります。

ただし、初心者が覚えておくべき実務上の原則は、まずこちらです。

最新の社内情報や根拠文書を答えに反映したいなら、最初に検討するのは追加学習ではなく、検索とコンテキストの設計です。

なぜなら、会社の規程、製品価格、組織、人事制度、在庫、顧客対応ルールは変わるからです。変わる情報をモデルの重みに深く埋め込むより、正しい最新版を必要なときに参照させるほうが、更新しやすく、根拠も示しやすいからです。

学習は「能力や傾向を身につける」こと。

推論は「いまの質問と資料を使って答える」こと。

RAGは「推論の前に、必要な資料を探して渡す」こと。

この三つを分けて考えてください。

続いて、身近な具体例で理解を深めましょう。

一つ目は、スマートフォンの文字入力です。

あなたが「おつ」と入力すると、「おつかれさま」「おつかれ」「お疲れ様です」などの候補が出てきます。これは、過去の大量の文章や、場合によってはあなた自身の入力傾向をもとに、続きそうな文字や単語を推論している例です。

この候補表示が自然なのは、AIが日本語の文脈を学習しているからです。しかし、「次に何を打つか」を実際に計算しているのは、あなたが入力するその瞬間です。ここに、学習と推論の違いがあります。

二つ目は、写真アプリの人物検索です。

写真アプリで「犬」「海」「料理」と検索すると、該当しそうな写真が並びます。画像を理解するモデルが、事前の学習で、犬や海、料理の視覚的な特徴を捉えられるようになっています。そして、実際にあなたが検索したときには、検索語と写真の特徴を比べて結果を返します。学習済みの能力を使った推論です。

三つ目は、動画配信や音楽配信のおすすめです。

サービスは、あなたが見た作品、途中で止めた作品、似た人の行動、作品のジャンルや説明文など、多くの情報から「次に興味を持ちそうなもの」を推測します。ここでは、ユーザーや作品をベクトルとして表し、近さを使って候補を探すこともあります。そして最後に、どの作品をどの順番で見せるかを推論します。

四つ目は、カーナビや地図です。

渋滞予測モデルは、過去の交通量や曜日、時間帯、天候、道路状況などからパターンを学びます。そして、あなたが今、目的地を設定したときには、現在の交通状況も加味して到着予想時刻を推論します。

学習は過去からパターンを身につけること。推論は現在の入力に対して答えを出すこと。この見方をすると、日常のAIが整理できます。

次に、実務での実用例です。

まず、カスタマーサポートを考えましょう。

顧客から「注文をキャンセルしたい」「領収書を再発行したい」「この製品は海外で使えるか」といった質問が届きます。

ここでAIに必要なのは、一般的な会話能力だけではありません。自社の返品規定、製品仕様、受注状況、顧客の契約内容など、正しい根拠です。

実用的な構成は、次のようになります。

まず、質問を受け取る。

次に、質問の意味をEmbeddingに変換する。

社内のFAQや規約から、意味が近い文書を検索する。

必要なら、注文管理システムから該当注文の状態を取得する。

その情報をコンテキストに入れて、LLMに回答案を作らせる。

そして、返金や契約変更のように影響が大きい処理は、人の承認か、明確なルール確認を通して実行する。

ここでモデルの追加学習が必ず必要とは限りません。むしろ、まずは正しい情報を検索して渡し、回答に引用元や根拠を添える設計のほうが、運用しやすいことが多いです。

次に、営業の例です。

営業担当者が商談前に、顧客企業の過去の商談記録、問い合わせ履歴、導入製品、提案資料を把握したいとします。

AIに「この顧客向けの打ち合わせ準備メモを作って」と依頼します。推論の前に、CRM、議事録、メール、過去提案書から関連情報を検索します。AIは、探し出された根拠をもとに、顧客の課題仮説、確認すべき質問、提案の論点、次回アクションの案を作れます。

ただし、売上予測や顧客の意図について、AIの文章を事実のように扱ってはいけません。特に「課題があるはず」「予算がある可能性が高い」といった部分は、推論や仮説です。実際の記録に書かれた事実と、AIがそこから作った提案を分けて表示することが大切です。

三つ目は、ソフトウェア開発です。

AIにコードを書かせる場面では、推論時に、既存のコード、設計書、テスト、エラーログ、ライブラリの仕様を読ませます。良いコード生成は、モデルの能力だけで決まりません。どのファイルをコンテキストに入れるか。最新の仕様をどう渡すか。テストでどう検証するか。この設計で大きく変わります。

AIが提案したコードは、必ずテストし、セキュリティや権限、例外処理、個人情報の扱いをレビューしてください。AIは高速な下書き担当として非常に役立ちますが、実行責任までは引き受けてくれません。

四つ目は、製造や物流です。

工場のカメラ画像から傷や欠けを見つける画像AI、需要を予測するAI、配送ルートを提案するAIなども、学習と推論の組み合わせです。

過去の正常品・不良品の画像で学習し、現場の新しい画像を受け取るたびに推論する。過去の出荷量や季節性を学習し、翌週の需要を推論する。こうした仕組みです。

現場で重要なのは、推論結果を「自動で決める最終判断」にするのか、「人に注意を促す補助情報」にするのかを明確に決めることです。不良品の見逃しが重大事故につながるなら、AIの判定だけで流さず、人の二重確認を入れるべきかもしれません。

ここからは、実装例です。

今日は長いコードを読むのではなく、社内文書に答えるシンプルなAIアシスタントを、頭の中で組み立ててみましょう。

目的は、「経費精算のルールについて社員の質問に答えるAI」です。

手順は五つです。

第一に、経費規程、申請マニュアル、よくある質問といった文書を集めます。古い版や重複文書が混じっていると、AIは矛盾した回答を作りやすくなります。ここで最初に必要なのは、AIモデルではなく、情報の整理です。

第二に、長い文書を小さなまとまりに分けます。これをチャンク分割と呼びます。たとえば、「交通費」「宿泊費」「交際費」「申請期限」のように、話題の区切りで分けます。

第三に、それぞれのチャンクをEmbeddingに変え、ベクトルデータベースに保存します。Day 3で学んだ部分ですね。文章そのものだけでなく、更新日、規程の版番号、対象部署、公開範囲などの情報も一緒に持たせます。

第四に、ユーザーが「出張のホテル代に上限はありますか」と質問したら、その質問もEmbeddingに変えます。そして、意味が近いチャンクを検索します。このとき、「最新の規程だけ」「営業部向けだけ」といった条件で絞り込めるようにします。

第五に、検索で得た文章をLLMへ渡します。その際、指示を明確にします。

「与えられた社内規程だけを根拠に回答してください。根拠が不足している場合は、推測せず、担当部署への確認を案内してください。回答には規程名と改定日を示してください。」

こうして、LLMが推論を行います。

実装の考え方を、短い疑似コードで表すなら、次のようになります。

「質問を受け取る。質問をベクトル化する。関連する社内規程を検索する。検索結果と質問をAIに渡す。根拠付きの回答案を返す。」

ここで重要なのは、AIに「答えを知っているふり」をさせないことです。

検索結果に必要な情報がないなら、「資料内では確認できません」と答える。規程の改定日が古いなら、「最新性を確認してください」と表示する。人事や経理への申請処理を実行するなら、権限確認と承認フローを入れる。

これが、実務で信頼できるAIを作る基本です。

また、改善の順番も覚えておきましょう。

AIの回答が悪いとき、すぐに「モデルを再学習しよう」と考える必要はありません。

まず、検索で正しい資料が取れているか。

次に、資料の分割が適切か。

次に、指示文が明確か。

次に、更新日や部署などの絞り込み条件があるか。

そして、評価用の質問集で品質を測っているか。

多くのケースでは、推論時のコンテキスト設計を改善するだけで、回答品質が大きく上がります。

それでは、今日のAI最新情報です。今日は、2026年8月16日時点で確認できる公式発表のうち、学習と推論というテーマにつながる四件を取り上げます。

一件目。Googleは2026年8月13日、コーディングやエージェント利用を主な対象とする「Gemini 3.7 Flash」を発表しました。Googleは、複数段階の計画やツール呼び出しにより丁寧に取り組むこと、ソフトウェア開発や知識集約型の仕事での改善を説明しています。今日のテーマとの関係で言えば、注目点は「学習済みモデルの性能」だけでなく、推論時にどれだけ計画し、ツールを使い、途中で状況を確認できるかが、実務の使いやすさを左右している点です。AIは単に一文を返すだけでなく、検索、ファイル整理、メール下書きなどの段取りを含めた推論へと広がっています。もっとも、発表にある性能値は提供企業自身の評価を含むため、個別の業務での効果は、自社データと自社タスクで検証する必要があります。([blog.google](https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-gemini-3-7-flash/))

二件目。OpenAIは2026年8月11日、サイバーセキュリティ向けのDaybreakモデル群をAmazon Bedrockで利用可能にしたと発表しました。対象となる利用者には、脆弱性の調査、検証、検知ルール作成、インシデント対応といった防御目的のワークフローが示されています。ここで大切なのは、推論能力が高まるほど、万能なチャット用途だけでなく、専門領域ごとのモデル、アクセス制御、利用者の審査、監査といった運用設計が重要になることです。特にサイバー分野では、AIの能力そのものと同じくらい、「誰が、何の目的で、どの権限で使うか」が重要です。([openai.com](https://openai.com/index/daybreak-models-are-now-available-on-aws/))

三件目。AWSは2026年8月5日、Amazon DynamoDBでリアルタイムのベクトル検索が一般提供になったと発表しました。Embeddingと業務データを同じデータベースで扱い、意味検索やRAG、推薦、エージェントの記憶といった用途を構築しやすくするものです。これはDay 3と今日の橋渡しになるニュースです。推論の質は、モデルの賢さだけで決まりません。質問に対して、どの情報を正しく、速く取り出し、コンテキストに渡せるかが重要です。ベクトル検索が業務データの近くに置けるようになる流れは、AIを実験から実運用へ進める際の基盤になり得ます。([aws.amazon.com](https://aws.amazon.com/blogs/aws/amazon-dynamodb-now-supports-real-time-vector-search-at-any-scale/))

四件目。Metaは2026年7月27日、ピッツバーグ大学の支援ロボティクスの取り組みで、オープンソースの視覚AIモデルが使われている事例を公開しました。カメラ画像を端末側で処理し、周囲の物体を認識するような用途では、クラウドに送ってから待つのではなく、機器の近くで素早く推論する、エッジ推論が重要になります。今日のテーマに引きつけると、学習は大規模な計算環境で行われる場合であっても、推論はスマートフォン、工場設備、車いす、ロボットなど、現場の制約に合わせて実行されるということです。実世界でAIを使うほど、精度だけでなく、応答速度、電池、通信断、安全性まで含めて考える必要があります。([ai.meta.com](https://ai.meta.com/blog/assistive-robotics-university-of-pittsburgh-sam-dino/))

ここで、今日の要点を整理しましょう。

一つ目。

学習は、データをもとにAIのパラメータ、つまり内部の調整つまみを変える工程です。予測の誤差を小さくするように、何度も調整します。

二つ目。

推論は、学習済みのAIに、いまの質問や資料を渡して答えを計算させる工程です。チャットAIとの会話、要約、分類、画像認識、推薦など、普段の利用で行われているのは主に推論です。

三つ目。

AIに会話で情報を伝えても、通常はモデルそのものが恒久的に学習しているわけではありません。多くの場合、その会話はコンテキストとして一時的に使われています。

四つ目。

最新の社内情報を答えに反映したい場合、まず検討すべきはRAGです。検索で根拠資料を探し、推論時のコンテキストとして渡します。変化の多い情報を扱うのに向いています。

五つ目。

追加学習は有力な手段ですが、万能薬ではありません。情報が古い、検索が不十分、指示が曖昧といった問題は、再学習だけでは解決しません。

六つ目。

実務では、モデルの性能だけでなく、データの鮮度、検索、権限、ログ、評価、人の最終確認を組み合わせることが重要です。

学習は「能力を作る」。

推論は「今の仕事をこなす」。

この区別を、今日の一番大事な持ち帰りにしてください。

最後に、1分理解チェックです。答えは、少し考えてから聞いてください。

第1問。

チャットAIに社内ルールを貼り付けて質問したとき、その会話中にAIが回答する働きは、主に学習でしょうか、推論でしょうか。

答えは、推論です。会話中の資料をコンテキストとして使い、学習済みの能力で回答を作っています。

第2問。

AIの予測と正解のずれを数値化したものを、何と呼ぶでしょうか。

答えは、損失、またはロスです。学習では、このロスを小さくする方向にパラメータを調整します。

第3問。

最新の就業規則を参照して答える社内AIを作りたいとき、最初に有力な方法は、モデルを再学習することと、規程を検索してコンテキストに渡すことのどちらでしょうか。

答えは、後者です。検索してコンテキストに渡す、RAGの考え方が有力です。規程が変わっても更新しやすく、根拠も確認しやすくなります。

第4問。

AIが長く考えるモードを使った場合、必ず正しい答えになるでしょうか。

答えは、いいえです。推論に時間や計算を多く使っても、入力情報の誤り、情報不足、モデルの限界は残ります。重要な業務では検証が必要です。

第5問。

「AIの回答品質を上げたい」と思ったとき、最初から追加学習だけを考えるべきでしょうか。

答えは、いいえです。検索対象の文書、文書の分割、コンテキスト、指示文、評価方法を見直すことで改善できることが多くあります。

次回、Day 5のテーマは、「モデル、データ、アルゴリズム」です。

今日、学習と推論という二つの工程を学びました。次回は、その学習を成り立たせる三要素に進みます。AIモデルとは何か。データの質がなぜ重要なのか。アルゴリズムは何を決めているのか。この三つを整理すると、ニュースで見かける「モデル性能」「学習データ」「新手法」という言葉を、より正確に読み解けるようになります。

それでは、今日もよい一日を。AI Daily Academyでした。

参考情報・一次情報

タイトル: Gemini 3.7 Flash: our most intelligent workhorse model

発行元: Google

発表日: 2026年8月13日

URL:

<https://blog.google/innovation-and-ai/models-and-research/gemini-models/introducing-gemini-3-7-flash/>

タイトル: Daybreak models are now available on AWS

発行元: OpenAI

発表日: 2026年8月11日

URL:

<https://openai.com/index/daybreak-models-are-now-available-on-aws/>

タイトル: Amazon DynamoDB now supports real-time vector search at any scale

発行元: AWS News Blog

発表日: 2026年8月5日

URL:

<https://aws.amazon.com/blogs/aws/amazon-dynamodb-now-supports-real-time-vector-search-at-any-scale/>

タイトル: Reimagining Independence: How Meta 's AI Models Are Helping the University of Pittsburgh Transform Assistive Robotics

発行元: Meta AI

発表日: 2026年7月27日

URL:

<https://ai.meta.com/blog/assistive-robotics-university-of-pittsburgh-sam-dino/>