

AI Daily Academy

day 004 2026-08-14

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

1. オープニング

おはようございます。AI Daily Academy、Week 1「AIの全体像」、Day 4です。

今日のテーマは、「学習と推論」です。

これまでの3日間で、生成AIとLLM、トークンとコンテキスト、そしてEmbeddingとベクトルを学びました。今日は、それらが実際にどうつながっているのかを理解する回です。

AIは、いつ何を覚えて、いつ目の前の質問に答えているのか。

「学習」と「推論」は、似た言葉に見えますが、実務では明確に分けて考える必要があります。

たとえば、皆さんがチャットAIに「この会議メモを要約して」と頼んだとき、AIはその場で新しい知識を身につけているのでしょうか。

答えは、通常は違います。多くの場合、AIはすでに学習済みのモデルとして動き、入力された会議メモを材料に、その場で出力を計算しています。これが推論です。

今日は、AIが大量のデータからパターンを身につける学習の仕組みと、学習済みのAIが質問に答える推論の仕組みを、通勤中에서도頭に絵が浮かぶように解説します。

最後には、業務でAIを使うときに、「これはモデルを学習し直すべき課題なのか」「検索やプロンプトの工夫で解ける課題なのか」を見分けるための判断軸もお持ち帰りいただきます。

では、始めましょう。

2. 前回の復習

まず、昨日までの内容を短く振り返ります。

Day 1では、生成AIとLLMについて学びました。

LLM、つまり大規模言語モデルは、文章の続きを予測することを基本に、文章作成、要約、翻訳、質問応答、コード生成など、幅広い仕事をこなします。

Day 2では、トークンとコンテキストを扱いました。

AIは文章を人間のように一文ずつ読んでいるのではなく、文字列をトークンという細かい単位に分けて処理します。そして、今の会話や資料など、モデルが回答前に参照できる範囲をコンテキストと呼びます。

Day 3では、Embeddingとベクトルを学びました。

Embeddingは、文章や画像などの意味を数値の並び、つまりベクトルに変換する技術です。意味が近いものは、ベクトル空間でも近くに置かれやすくなります。これにより、単なるキーワード一致ではなく、「意味が似ている資料」を探せるようになります。

ここまでを一つの流れで言うと、こうです。

AIは入力をトークンとして受け取り、必要ならEmbeddingで意味の近い情報を検索し、コンテキストに材料を集めます。そして、学習済みのモデルが、その材料をもとに次のトークンを予測し続けて、回答を生成します。

今日の主役は、この「学習済み」という部分と、「予測して回答する」という部分です。

3. 今日の基礎講義

まず結論です。

学習とは、AIモデルの内部にあるパラメータを調整して、データのパターンを身につけさせる工程です。

推論とは、学習済みのパラメータを固定した状態で、新しい入力に対して出力を計算する工程です。

少し言葉を分けて見てみましょう。

AIモデルの中には、非常にたくさんの数値があります。これをパラメータ、あるいは重みと呼びます。

人間でいえば、経験によって形成された「ものの見方の癖」や「判断のつながり」に少し似ています。ただし、AIのパラメータは、意味のある文章で保存された知識カードではありません。膨大な数値の組み合わせとして、言葉、表現、構文、世界に関するパターンなどが分散して表されています。

学習では、AIに大量の例を見せます。

たとえば、

「東京は日本の首都です」

という文章を見せたとします。

言語モデルの訓練では、ある位置までの言葉を手がかりに、その次に来るトークンを当てる問題を大量に解きます。

「東京は日本の」の次なら、「首都」が来る可能性を高くする。

「首都です」の次には、文末らしいトークンが来る可能性を高くする。

こうした予測を、非常に多くの文章に対して繰り返します。

もちろん、実際の学習は単純な穴埋め帳ではありません。モデルは文章の前後関係、長い距離のつながり、言い回しの違い、複数の概念の関係を利用しながら、次に何が現れそうかを確率として出します。

予測が正解から遠ければ、モデルには損失、つまり「どのくらい外れたか」を表す数値が与えられます。

その損失を小さくする方向へ、パラメータをほんの少しずつ更新します。

この更新を、何度も何度も繰り返す。

これが、機械学習の基本です。

重要なのは、AIが一つの事実を丸ごと一行で暗記しているわけではない、という点です。

学習の結果として、言葉と言葉の関係や、文脈に応じた使われ方の傾向が、モデル全体に分散して組み込まれます。

では推論とは何でしょうか。

推論では、通常、学習済みの重みは変更しません。

ユーザーが入力した文章をトークンに分け、コンテキストとしてモデルに渡します。モデルは、次に来るトークンの候補ごとに確率らしきスコアを計算します。そして、一つを選びます。選んだトークンを文脈に追加し、また次のトークンを選びます。

この繰り返しで、文章が一語ずつ生成されます。

たとえば、「営業会議の議事録を3点で要約して」と入力したとしましょう。

モデルは完成した要約文を最初から持っているわけではありません。まず「1」や「・」や「今回」といった最初のトークンの候補を計算し、一つ選びます。次に、その直前までの出力を含めて、次のトークンを計算します。

つまり生成AIは、文章を一括で印刷しているのではなく、次の一手を連続的に決めながら、出力を組み立てています。

ここで、日常語としての「推論」と、AI業界での「inference」という言葉には少し注意が必要です。

日常語の推論は、根拠から結論を導く思考を指します。

一方で、機械学習の推論は、もっと広く、学習済みモデルを使って入力から出力を得る処理全般を意味します。分類でも、翻訳でも、画像認識でも、生成でも、学習後に新しいデータへ答えを返す処理は推論です。

最近「推論モデル」や「reasoning model」という言葉もよく見かけます。これは、難しい問題に対して、より多くの計算時間やトークン、場合によってはツールを使い、途中で検証しながら答えを作る設計を指すことが多いです。

ただし、モデルが長く考えるように見えることと、常に正しいことは別です。

出力がもっともらしくても、事実確認、計算確認、ルール確認が必要な場面は残ります。

4. 仕組み・応用

ここからは、学習と推論をもう一段、実務寄りに整理します。

AI開発には、大きく分けて三つの段階があります。

一つ目は、事前学習です。

大量のテキスト、コード、画像、音声などから、幅広いパターンを学ぶ段階です。大規模言語モデルが、一般的な文章能力や多言語能力、コードの書き方などの土台を作るのがここです。

二つ目は、追加学習、あるいはポストトレーニングです。

人間にとって役立つ答え方、安全な振る舞い方、指示への従い方などを調整します。質問への答え方、拒否すべき依頼の扱い、会話の自然さなどは、この段階の工夫が大きく影響します。

三つ目が、利用時の推論です。

ここではユーザーの入力、業務データ、検索結果、社内文書などをコンテキストに入れ、学習済みモデルに回答を作らせます。

この三つを混同しないことが重要です。

たとえば、社内規程が来月改定される場合を考えてみましょう。

この改定内容をAIに答えさせたいからといって、必ずしもモデルを再学習する必要はありません。

むしろ多くのケースでは、最新の規程を文書データベースに入れ、Embeddingで検索し、関連箇所をコンテキストに渡すRAG、つまり検索拡張生成を使う方が現実的です。

なぜなら、規程は変わるからです。

変化する情報をモデルのパラメータに直接覚え込ませると、更新が重くなり、いつの版を答えているのかも管理しづらくなります。

一方で、毎回の出力形式を厳密にそろえたい、専門分野独特の表現に強くしたい、ある決まった分類を安定して行いたい、といった課題では、追加学習やファインチューニングが候補になります。

ここで、よくある誤解を一つ解いておきましょう。

「AIに資料をアップロードしたから、AIはそれを学習した」

これは、必ずしも正しくありません。

多くの業務用AIでは、アップロードした資料は、その会話や検索のためのコンテキストとして参照されます。モデルそのもののパラメータを書き換える学習とは別の処理です。

この違いは、情報管理の説明でも大切です。

「会話のために参照する」のか。

「サービス改善やモデル訓練に使われる可能性がある」のか。

「自社専用の追加学習データとして使う」のか。

これらは契約、設定、提供形態によって異なります。実務では、利用中のサービスのデータ利用条件、保持期間、管理者設定を確認してください。

推論の品質は、モデルの性能だけで決まりません。

大きく四つの要素があります。

一つ目は、入力の詳細さです。

目的、対象読者、形式、制約、判断基準を具体的に渡すほど、モデルは迷いにくくなります。

二つ目は、コンテキストの品質です。

古い資料、矛盾した資料、関係ない資料を大量に入れると、強いモデルでも答えはぶれます。

三つ目は、検索の品質です。

Embedding検索で関連資料を取り出す場合、正しい資料が上位に来なければ、モデルには正しい根拠が届きません。

四つ目は、出力後の検証です。

特に、金額、法令、契約条件、人事判断、医療、セキュリティ、対外公表の文章では、人間のレビューと根拠確認を工程に入れます。

AIは、学習で得た一般的な能力と、推論時に与えられた具体的な材料を組み合わせます。

言い換えると、モデルは「書き方・考え方のエンジン」、検索された社内文書は「今回の判断材料」です。

この役割分担を理解すると、AI導入の設計がずっと明快になります。

5. 身近な具体例

ここで、身近な例で考えてみましょう。

第一の例は、スマートフォンの予測変換です。

あなたが「おつ」と入力すると、「おつかれさまです」や「お疲れ様です」といった候補が出てきます。これは、過去の言語データや利用履歴などから、次に続きやすい文字や単語を予測する発想に近いものです。

ただし、最新のLLMは、より長い文脈を扱い、文章の目的や構成も踏まえて生成できます。予測変換の高度で大規模な親戚、と考えるとイメージしやすいでしょう。

第二の例は、料理です。

料理人が多数のレシピや調理経験から、「この食材なら、こういう味付けが合う」と身につけるのが学習に近い部分です。

そして、冷蔵庫にある食材と、今日の人数、予算、アレルギーという条件を見て、今夜の献立を考えるのが推論に近い部分です。

料理人が過去に学んだことだけでは、今日の冷蔵庫の中身は分かりません。

同じようにAIも、推論時に最新の情報を与えなければ、今日の在庫や今週の制度改定を正確には扱えません。

第三の例は、試験勉強です。

参考書を読み、問題を解き、間違いを直すのが学習です。

試験当日に、新しい問題を読んで答えるのが推論です。

ここで重要なのは、試験中に教科書を見られるなら、正確な答えを出しやすくなることです。

AIにとっての検索やRAGは、条件付きで参照できる教科書に似ています。ただし、AIが参照箇所を誤って選ぶことも、教科書を誤読することもあります。だから、根拠の表示と人の確認が重要になります。

第四の例は、顔認証です。

大量の顔画像から特徴を学ぶ工程が学習で、新しい顔画像を入力して本人らしさを判定するのが推論です。

この場合、推論は文章を生成しません。それでも学習済みモデルが新しい入力に答えを返しているため、推論と呼ばれます。

6. 実務での実用例

では、職場ではどのように使い分けるのでしょうか。

まず、営業部門を例にします。

営業担当者が「A社向けの提案書を作りたい」とします。

AIに必要なのは、一般的な提案書の構成能力、読みやすい文章を書く力、業界用語を扱う力です。これは主に事前学習と追加学習で得られた能力です。

一方で、A社の最新の課題、商談履歴、競合状況、価格表、契約上の制約は、推論時に渡すべき情報です。

ここでRAGを使い、CRM、過去提案書、製品資料から関連情報を検索して、根拠付きの下書きを作らせます。

次に、カスタマーサポートです。

FAQが頻繁に更新される企業なら、毎回ファインチューニングするより、最新のナレッジベースを検索する方式が向きます。

ただし、回答の口調、エスカレーションの基準、必ず確認事項を聞く順序などは、プロンプト、テンプレート、ワークフロー、場合によっては追加学習で安定させる価値があります。

経理や法務では、さらに慎重が必要です。

請求書を読み取って項目を抽出する、契約書の差分候補を見つける、社内ルールに照らして確認事項を出す、といった作業にはAIが役立ちます。

しかし、最終承認まで自動化するかは別問題です。

AIが行うのは、候補作成、抜け漏れ検知、優先順位付け、根拠の整理までにとどめる。そして、責任者が最終判断する。この設計が現実的な場面は多くあります。

人事では、応募書類の要約や面接メモの構造化に使えます。

一方で、採否の判断に直接使う場合は、公平性、説明可能性、個人情報、法的な要件を慎重に確認する必要があります。AIの出力を「客観的な結論」と見なさないことが大切です。

ここで、実務の判断フレームを一つ紹介します。

情報が頻繁に変わるなら、まず検索とコンテキスト設計を検討する。

情報は固定的だが、出力の型や専門的な振る舞いを安定させたいなら、追加学習を検討する。

誤りのコストが高いなら、根拠表示、ルールベースのチェック、人間の承認を組み合わせる。

この順番です。

「AIに全部覚えさせればいい」という発想から離れ、

「どの情報を、いつ、どの根拠として渡すか」を設計する。

これが、AI活用の実務力になります。

7. 実装例

ここでは、社内規程の質問に答えるAIを、最小構成で考えてみます。

利用者が、「出張時の宿泊費の上限はいくらですか」と質問したとします。

実装の流れは、五段階です。

第一に、社内規程を一定の長さごとの断片、チャンクに分けます。

一文だけでは意味が足りず、一冊丸ごとでは検索しにくいいため、見出しや段落を保ちながら、適度な大きさに分割します。

第二に、各チャンクをEmbeddingに変換し、ベクトルデータベースに保存します。

このとき、文書名、版数、施行日、部署、公開範囲などのメタデータも一緒に持たせます。

第三に、ユーザーの質問もEmbeddingに変換します。

そして意味が近い規程のチャンクを検索します。ここでは、最新版だけを対象にする、経費規程を優先する、といった絞り込みが大切です。

第四に、検索で見つかった規程の文章を、質問とともにLLMへ渡します。

指示には、「根拠として渡された文書だけを使うこと」「根拠が不足するときは推測せず、不明と答えること」「回答とともに規程名・条項を示すこと」と書きます。

第五に、出力を画面へ返す前に、必要に応じてチェックします。

たとえば金額表記が原文に存在するか、施行日が最新か、根拠を示せているかを確認します。

コードの雰囲気だけ、短く見てみましょう。これは特定のクラウドや製品に依存しない疑似コードです。

```
``python
question = "出張時の宿泊費の上限はいくらですか"

hits = vector_search(
    query=embed(question),
    filters={"document_type": "経費規程", "status": "最新版"},
    top_k=4
)

context = "\n\n".join(hit.text for hit in hits)

prompt = f"""
質問: {question}

根拠資料:

{context}

根拠資料だけを使って回答してください。
金額、適用条件、規程名、条項を示してください。
資料に答えがなければ、推測せず「確認が必要」と答えてください。
"""

answer = generate(prompt)

print(answer)
``
```

この実装で重要なのは、最後の `generate`、つまり文章を作る部分だけではありません。

むしろ品質を大きく左右するのは、その前の検索です。

誤った規程、古い規程、海外拠点向けの規程を取ってきたら、生成モデルがいくら流暢でも答えは危うくなります。

また、検索結果がゼロ件だったときに、モデルへ無理に答えさせない設計も必要です。

「分からない」と返せることは、業務AIの品質の一部です。

学習と推論の視点で見ると、この仕組みでは、規程をモデルに再学習させていません。

規程は外部データとして保持し、推論時に必要な箇所だけを渡しています。だから、規程が改定されても、文書を更新し、Embeddingを作り直し、古い版を検索対象から外せば対応しやすくなります。

8. 今日のAI最新情報

ここからは、2026年8月14日時点で確認した、今日のテーマに関係する最近のAI情報です。

ここで紹介するのは、8月14日に発表されたニュースではなく、発表日を確認できる比較的新しい公式発表です。

一件目。

Anthropicは2026年6月30日、Claude Sonnet 5を発表しました。発表では、推論、ツール利用、コーディング、長い作業を自律的に進めるエージェント的な能力を重視しています。また、利用者が作業の難しさに応じて、計算量とコストのバランスを選ぶ考え方も示されています。

今日のテーマとの関係は明確です。

モデルの「学習済み能力」だけでなく、推論時にどれだけ計算を使うか、どのツールを呼ぶかで、回答品質、処理時間、コストが変わるということです。業務では、簡単な要約と、高リスクな調査・検証を同じ設定で扱わない設計が重要になります。

二件目。

OpenAIは2026年6月25日、エージェントが仕事をどう変えているかに関する分析を公開しました。ここでは、短い一問一答よりも、複数のツールを使いながら長い作業を進める利用が広がっていると説明されています。

これは、推論が単に「一度回答を返す処理」から、「計画し、情報を取り、実行し、結果を見て修正する一連の処理」へ広がっていることを示します。

ただし、長いタスクを任せられることと、監督なしで任せてよいことは同じではありません。特に外部システムへの書き込み、購入、顧客連絡、権限変更などは、承認フローと実行範囲の制限が必要です。

三件目。

AWSは2026年7月23日、Black Hat USA 2026に向けた公式記事で、AIエージェントを含む環境でのセキュリティ運用と、自律的な防御をテーマに取り上げました。

今日のテーマに引きつけると、推論の能力が高くなり、AIがツールを使えるようになるほど、AIの出力だけでなく「AIが何を実行できるか」が重要になります。

AIに社内検索だけを許可するのか。メール送信も許可するのか。データベースの更新まで許可するのか。推論モデルの性能評価と並行して、権限設計、ログ、監視、停止手段を用意する必要があります。

四件目。

OpenAIは2026年7月8日、教育者向けの実践的なAIスキル支援について発表しました。内容は教育分野向けですが、単にAIを使えるようにするのではなく、現場の課題を持ち寄り、試し、懸念を共有しながら使い方を身につけることを重視しています。

これは企業のAI導入にもそのまま当てはまります。

学習と推論の技術的な違いを知るだけでは十分ではありません。どの仕事に使うのか。どの情報を渡してよいのか。どの出力を人が確認するのか。現場の業務に沿って、繰り返し試すことがAIリテラシーにつながります。

四つのニュースに共通しているのは、AIの競争が「より大きく学習したモデル」だけの話ではなくなっていることです。

推論時の計算配分、ツール利用、データ連携、監督と安全設計、現場への定着。これらすべてが、AIの価値を決める段階に入っています。

9. 今日の要点整理

今日のポイントを、五つにまとめます。

一つ目。

学習は、データを使ってモデルのパラメータを更新する工程です。

推論は、学習済みモデルが新しい入力に対して出力を計算する工程です。

二つ目。

LLMは、文脈をもとに次のトークンを予測することを繰り返し、文章を生成します。

一度に完成文を取り出しているわけではありません。

三つ目。

社内規程や商品情報のように頻繁に変わる情報は、モデルへ覚え込ませるよりも、検索して推論時のコンテキストに渡す方式が向くことが多いです。

四つ目。

AIの品質は、モデルの性能だけで決まりません。

入力の詳細さ、検索の精度、参照データの新鮮さ、出力の検証が重要です。

五つ目。

エージェントのようにAIがツールを使って行動する場合、回答の正しさだけでなく、権限、監視、承認、停止手段を設計する必要があります。

覚えておきたい一文は、これです。

学習はAIの土台を作り、推論はその土台を使って、今この場の課題に答える。

10. 1分理解チェック

では、最後に理解チェックです。

答えは少し間を置いてからお伝えします。

第1問。

社内の旅費規程が改定されました。最新の上限額をAIに答えさせたい場合、最初に検討しやすいのは、モデルの再学習でしょうか。それとも最新版規程の検索とコンテキストへの追加でしょうか。

答えは、最新版規程の検索とコンテキストへの追加です。

頻繁に変わる情報は、外部データとして更新・検索する方が管理しやすいケースが多いです。

第2問。

推論とは、AIが必ず人間のように論理的思考をすることを指すでしょうか。

答えは、いいえです。

機械学習における推論は、学習済みモデルが新しい入力から出力を得る処理全般を指します。

第3問。

アップロードした資料をチャットAIが回答で参照した場合、その資料は必ずモデル本体に学習されたと言えるでしょうか。

答えは、言えません。

多くの場合、資料は会話時のコンテキストや検索対象として参照されます。モデルのパラメータを更新する学習とは別です。

第4問。

RAG型の社内QAで、回答品質を大きく左右する要素を一つ挙げるとしたら何でしょうか。

答えの例は、検索品質です。

正しい最新版の根拠資料を取ってこられるかどうか、回答の信頼性に直結します。

第5問。

AIエージェントにメール送信やデータ更新を許可する場合、必要になる設計を二つ挙げてください。

答えの例は、権限の制限、実行ログ、承認フロー、監視、停止手段です。

能力が高いことと、無制限に実行してよいことは別です。

11. 次回予告

次回、Day 5のテーマは「プロンプト設計」です。

今日学んだように、推論時のAIは、与えられた入力とコンテキストをもとに答えを作ります。

つまり、AIに何を、どの順番で、どんな制約とともに伝えるかで、出力は大きく変わります。

今回は、曖昧な依頼を、AIが仕事として実行しやすい指示へ変える方法を学びます。

目的、前提、役割、出力形式、評価基準、禁止事項。これらをどう組み立てるかを、すぐ使える形で解説します。

今日もお疲れさまでした。

AI Daily Academy、Day 4はここまでです。

参考情報・一次情報

1. タイトル: Introducing Claude Sonnet 5

発行元: Anthropic

発表日: 2026-06-30

URL:

<https://www.anthropic.com/news/claude-sonnet-5>

([anthropic.com](https://www.anthropic.com/news/claude-sonnet-5?_rsc=304t7&utm_source=openai))(

https://www.anthropic.com/news/claude-sonnet-5?_rsc=304t7&utm_source=openai

2. タイトル: How agents are transforming work

発行元: OpenAI

発表日: 2026-06-25

URL:

<https://openai.com/index/how-agents-are-transforming-work/>

([openai.com](https://openai.com/index/how-agents-are-transforming-work/?utm_source=openai))(

https://openai.com/index/how-agents-are-transforming-work/?utm_source=openai

3. タイトル: Enterprise security at machine speed: AWS Black Hat 2026 preview

発行元: Amazon Web Services

発表日: 2026-07-23

URL:

<https://aws.amazon.com/blogs/security/enterprise-security-at-machine-speed-aws-black-hat-2026-preview/>

([aws.amazon.com](https://aws.amazon.com/blogs/security/enterprise-security-at-machine-speed-aws-black-hat-2026-preview/?utm_source=openai))(

https://aws.amazon.com/blogs/security/enterprise-security-at-machine-speed-aws-black-hat-2026-preview/?utm_source=openai

4. タイトル: Helping K – 12 educators build practical AI skills

発行元: OpenAI

発表日: 2026-07-08

URL:

<https://openai.com/index/k-12-educators-practical-skills/>

([openai.com](https://openai.com/index/k-12-educators-practical-skills/?utm_source=openai))(

https://openai.com/index/k-12-educators-practical-skills/?utm_source=openai