

AI Daily Academy

day 002 2026-08-14

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

AI Daily Academy、Week 1、Day 2へようこそ。

今日のテーマは、「トークンとコンテキスト」です。

昨日は、生成AIとLLM、大規模言語モデルについて学びました。生成AIは、文章、画像、音声、プログラムなどを新しく作り出すAIの総称でした。そしてLLMは、大量の文章を学習し、次に来そうな言葉を予測しながら、人間らしい文章を生成する仕組みでした。

ただし、LLMが文章を扱うとき、人間のように「単語」や「文」をそのまま読んでいるわけではありません。AIには、文章を細かな単位に分けて処理する独自の方法があります。その単位が、今日の主役である「トークン」です。

さらに、AIが会話の中で一時的に覚えておける情報の範囲を、「コンテキスト」と呼びます。

この二つを理解すると、なぜAIが長い会話の前半を忘れたように見えるのか。なぜ資料を丸ごと貼り付けても、期待した答えが返らないことがあるのか。なぜ同じ質問でも、指示の出し方によって結果が変わるのか。その理由が見えてきます。

今日は、AIをより正確に、より安全に、そして費用対効果よく使うための土台を作っていきましょう。

それでは始めます。

まず、前回の復習です。

Day 1では、生成AIは「もっともらしい答えを、学習したパターンをもとに作る技術」だと説明しました。ここで大切なのは、LLMは人間のように文章の意味を完全に理解して、頭の中に百科事典を持っているわけではない、という点です。

LLMは入力された文章を受け取り、その続きとして確率的に自然な並びを出力します。つまり、AIとの会話は、AIに質問を投げて終わりではありません。こちらが渡した情報、指示、会話の流れが、毎回の回答に影響します。

今日学ぶトークンとコンテキストは、まさにその「AIに何が渡り、どこまで参照され、どんなコストで処理されるか」を理解する言葉です。

では、トークンから見ていきましょう。

トークンとは、AIが文章を読むときの処理単位です。

たとえば私たち人間は、「今日の会議は午後3時です」という文を見たとき、「今日」「の」「会議」「は」「午後」「3時」「です」といった意味のまとまりで理解します。

一方でAIは、文章をもっと機械的な単位に分けます。単語ごとに分けることもあれば、単語の一部、漢字一文字、記号、数字、よく使われる文字の組み合わせなどに分けることもあります。

つまり、トークンは必ずしも単語ではありません。

英語では、短い単語ひとつが一つのトークンになる場合もあります。しかし、日本語は単語の間に空白がないため、分割のされ方が英語と異なります。「ありがとうございます」という言葉が、モデルによっては一つのまとまりとして扱われることもあれば、複数のトークンに分かれることもあります。

ここで覚えておきたいのは、文字数とトークン数は同じではない、ということです。

「100文字だから100トークン」とは限りません。日本語、英語、数字、記号、URL、プログラムのコードなどによって、トークン数は大きく変わります。特に、表、箇条書き、数字の多いデータ、ソースコード、長い固有名詞などは、見た目より多くのトークンを使うことがあります。

なぜこんな単位が重要なのでしょうか。

理由は三つあります。

一つ目は、AIの記憶できる量に関係するからです。

二つ目は、回答にかかる時間に関係するからです。

三つ目は、APIなどでAIをシステムに組み込む場合、費用に関係するからです。

順番に説明します。

まず、AIの記憶できる量です。

AIとのチャットでは、長く会話を続けると、前に伝えた話をAIが忘れたように見えることがあります。

たとえば、最初に「私は小さなカフェを経営しています」と伝えたとします。その後、メニュー、スタッフ、売上、SNS投稿、イベント企画について何十回も会話を続けます。そして最後に、「さっきの店向けに、今週の投稿案を作って」と頼む。

このときAIが、カフェではなく一般的な企業向けの投稿案を出してしまうことがあります。

これは、AIが急に理解力を失ったというより、会話全体が長くなりすぎて、最初の「カフェを経営している」という情報が、今の処理範囲から外れた可能性があります。

この、AIが一度の応答を作る際に参照できる情報の範囲が、コンテキストです。日本語では「文脈」や「前後関係」と訳されます。

コンテキストには、あなたが今入力した質問だけではなく、通常はさまざまな情報が入っています。

たとえば、AIの基本的な振る舞いを決めるシステム指示。

サービス側が用意したルール。

過去の会話。

添付した資料。

AIが外部ツールで取得した検索結果。

そして、AI自身がこれから出力する回答。

これらが、ひとつの限られた箱に入るイメージです。

この箱を、コンテキストウィンドウと呼びます。ウィンドウは窓という意味ですが、ここでは「AIが今見渡せる範囲」と考えると分かりやすいでしょう。

重要なのは、入力だけで箱が使われるわけではないことです。AIが生成する出力、つまり回答文にもトークンが必要です。

仮に、コンテキストウィンドウが大きいモデルであっても、長大な資料を入れすぎると、AIが十分な長さで答える余地が減ることがあります。資料を大量に貼り付けたのに、回答が短い。あるいは途中で切れる。こうした現象は、入力と出力が同じ処理枠を分け合うことと関係します。

ここで、よくある誤解を一つ解いておきましょう。

コンテキストが長いAIなら、何百ページの資料を渡しても、すべてを完璧に理解し、必要な箇所を正確に使える。これは期待しすぎです。

長いコンテキストは確かに便利ですが、多くの資料、議事録、契約書、仕様書、会話履歴を一度に扱える可能性が広がります。しかし、「入れられる量」と「正確に使いこなせること」は別です。

資料が長くなればなるほど、AIにとって大事な情報が埋もれる場合があります。特に、真ん中あたりに置かれた重要な条件を見落したり、似た情報を混同したりする可能性があります。

人間でも、300ページの資料を渡されて、「この中から例外条件だけ探して、間違いなく結論を出してください」と言われたら大変です。AIも同じように、情報量が増えるほど、問いの立て方や情報の整理が重要になります。

そこで、AIを使う側が持つべき基本姿勢があります。

「全部入れる」より、「必要なものを、分かる形で入れる」です。

たとえば社内規程をAIに要約させたい場合、いきなり数百ページを貼り付けて、「要約して」と頼むよりも、目的を決めます。

新入社員向けの説明なのか。

管理職向けの注意点なのか。

経費精算だけを知りたいのか。

在宅勤務のルールだけを知りたいのか。

目的が決まると、AIに渡す資料の範囲も、出力形式も絞れます。

「以下の規程から、一般社員が守るべき経費精算のルールだけを抽出してください。金額上限、申請期限、例外、必要書類を表にしてください。資料に書かれていないことは推測しないでください」

このように依頼すれば、AIが参照すべき情報と、作るべき答えの形が明確になります。

これが、コンテキストを設計するという考え方です。

AI活用では、プロンプト、つまりAIへの指示文ばかり注目されがちです。しかし実務では、良いプロンプトを書くこと以上に、「AIに何の情報を渡すか」「何を渡さないか」「どの順番で渡すか」が成果を左右します。

ここから、仕組みをもう少しだけ深掘りします。

LLMは、入力されたトークンの並びを見て、次に出すトークンを一つずつ選びます。

たとえば、「日本の首都は」という入力に対して、「東京」というトークン、あるいは「東」と「京」のような複数のトークンが、もっとも自然な続きとして選ばれます。

そして、「東京」の次には、「です」「である」「になります」など、文脈に合った候補が続きます。この予測を非常に高速に繰り返すことで、文章全体が作られます。

AIは、最初から完成した答えを一括で取り出しているわけではありません。一歩ずつ、次のトークンを予測しています。

この性質は、AIの強みと弱みの両方につながります。

強みは、文脈に応じて柔軟な文章を作れることです。同じテーマでも、「小学生向けに」「役員向けに」「箇条書きで」「丁寧なメール文で」と条件を変えれば、出力を大きく変えられます。

弱みは、AIがもっともらしい続き方を優先するため、事実確認が必要な場面でも、自然な文章を作ってしまう可能性があることです。これが、いわゆるハルシネーション、つまり事実と異なる内容をもっともらしく生成する現象につながります。

コンテキストに正しい資料を与えることは、ハルシネーションを減らすための有効な方法の一つです。ただし、ゼロにはできません。

AIに正しい資料を渡しても、AIが読み違える、引用箇所を取り違える、資料にない補足をしてしまう、といったことは起こり得ます。重要な判断では、出典を確認し、人間が最終確認する必要があります。

特に、法務、医療、採用、人事評価、融資、契約、個人情報の扱いなどでは、AIの出力をそのまま確定情報として使わないことが大切です。

では、コンテキストを上手に使う具体的な方法を、五つ紹介します。

一つ目は、最初に役割と目的を伝えることです。

「あなたは営業企画のアシスタントです」

「目的は、顧客訪問前の準備時間を短縮することです」

「回答は、事実、仮説、確認事項に分けてください」

このような指示は、AIが回答を組み立てるための土台になります。

二つ目は、前提情報を整理して渡すことです。

顧客情報、過去の提案、今回の商談目的、扱ってよい情報、扱ってはいけない情報を、短く構造化して渡します。長文のまま貼るより、「顧客概要」「課題」「今回のゴール」「制約条件」と見出しをつけるほうが、AIも人間も扱いやすくなります。

三つ目は、資料と指示を分けることです。

たとえば、先に「以下は参考資料です」と示し、その後に「資料だけを根拠に、回答してください」と依頼します。資料の本文と質問が混ざっていると、AIがどこまでが命令で、どこからが引用なのかを判断しにくくなることがあります。

四つ目は、出力形式を決めることです。

「結論を三行、その後に根拠、最後に不明点」

「表形式で、項目は課題、原因、対応案、優先度」

「300文字以内」

「資料内に根拠がない場合は、『資料に記載なし』と書く」

このような指定は、無駄な出力トークンを減らし、確認作業も楽にします。

五つ目は、長い仕事を分割することです。

一度に「100ページの資料を読んで、戦略を立てて、プレゼンを作って、想定問答も作って」と依頼するより、段階を分けます。

まず、資料の章ごとの要約。

次に、重要論点の抽出。

次に、意思決定に必要な追加情報の洗い出し。

その後、提案の骨子。

最後に、スライド構成と想定問答。

分けることで、途中で人間が方向修正できます。また、必要な情報だけを次の段階へ引き継げるため、コンテキストの無駄遣いを防げます。

ここで、身近な例を考えてみましょう。

一つ目は、旅行計画です。

あなたがAIに、「京都へ二泊三日で旅行します。おすすめを教えて」と頼んだとします。これでは情報が少ないため、一般的な観光地の一覧が返ってきやすいでしょう。

そこで、コンテキストを足します。

「夫婦二人、30代。2026年10月の平日。京都駅近くに宿泊。寺社より食と散歩を重視。朝は早く行動可能。予算は一人8万円。混雑をできるだけ避けたい。移動は公共交通機関。雨天案も必要」

ここまで条件があれば、AIはかなり具体的な旅程案を作りやすくなります。

ただし、店の営業時間、臨時休業、交通機関の時刻、イベント日程のように変動する情報は、AIの記憶だけに頼れません。検索機能や公式情報で確認する、あるいは自分で公式サイトを見る必要があります。

二つ目は、家族との連絡文です。

「祖母に送るメッセージを考えて」とだけ頼むよりも、「80代の祖母へ。敬語を使いすぎず、体調を気遣い、今週末に電話したいことを120文字以内で伝える」と伝える。

これだけで、AIに必要なコンテキストが整います。AIは、文章を作る道具として、とても使いやすくなります。

三つ目は、勉強です。

資格試験の教材をAIに貼り付けて、「要約して」と言うだけでは、どこが試験に重要なのか分からない要約になるかもしれません。

そこで、「この教材は初学者向けに学びます。試験で問われやすい定義、数字、例外条件を優先し、最後に四択問題を5問作ってください。教材にない知識は加えないでください」と指示します。

AIに与えるコンテキストと、出してほしい形式を明確にすることで、学習効率が上がります。

続いて、実務での実用例です。

まず営業です。

営業担当者が商談前に使う場合、顧客の公開情報、過去の商談メモ、自社の提案資料、今回の目的をAIに渡します。そして、「顧客の課題仮説を三つ。各仮説の根拠。商談で確認すべき質問。提案時に避けるべき表現」を整理させます。

ここでの注意点は、顧客情報の扱いです。個人情報、契約上の機密情報、未公開の業績情報などを、会社のルールを確認せずに外部AIへ入力してはいけません。業務で使うなら、利用規約、データの保存設定、学習利用の扱い、アクセス権限を確認することが前提です。

次に、カスタマーサポートです。

問い合わせ履歴、製品マニュアル、対応ルールをAIが参照できるようにすると、問い合わせへの下書きを早く作れます。このとき大切なのは、AIが社内資料を「知識」として永久に覚えるわけではない、という理解です。

多くの場合、必要な資料を検索して、その結果を毎回コンテキストに入れて回答を作ります。この方式は、RAG、ラグと呼ばれます。日本語では、検索拡張生成と訳されることがあります。

RAGとは、まず社内文書などから関連情報を検索し、その検索結果をAIに渡して回答させる仕組みです。

たとえば、「返品期限を教えて」という顧客の質問が来たとき、AIがマニュアルの該当箇所を検索し、その文をコンテキストに加えてから回答を生成します。

これなら、モデル自体を再学習させなくても、更新されたマニュアルを参照しやすくなります。

ただし、検索で間違った文書を取ってきたら、AIの答えも間違いやすくなります。RAGは魔法ではありません。文書の整理、更新日の管理、権限設定、検索精度の評価、出典表示、人間によるレビューが重要です。

人事部門でも、コンテキスト設計は役立ちます。たとえば社内規程をもとに、社員からの一般的な質問への回答案を作ることは可能です。しかし、個別の評価、処遇、採用可否、懲戒といった高い影響を持つ判断をAIだけに委ねるのは適切ではありません。

AIは規程の説明や、確認観点の整理には使えます。しかし、決定権者や責任の所在まで置き換えるものではありません。

ここで、簡単な実装例を考えてみましょう。

たとえば、社内FAQを答える小さなAIアシスタントを作るとします。

考え方は、四段階です。

第一に、社員から質問を受け取ります。

第二に、FAQや社内規程の中から、質問に関連する箇所を検索します。

第三に、見つかった文章と、回答ルールをAIに渡します。

第四に、AIが答えを作り、根拠を添えて表示します。

コードそのものは長くなるため、ここでは設計だけをイメージしてください。

AIに渡す指示は、次のような構造になります。

「あなたは社内FAQ担当です。回答は、提供された参考資料だけを根拠にしてください。根拠が不足している場合は、推測せず、担当部署への確認が必要だと答えてください。回答には、結論、根拠、次の行動を含めてください」

その後に、検索で見つかった規程の抜粋を追加します。最後に社員の質問を入れます。

この順番には意味があります。

先にルールを置く。

次に根拠資料を置く。

最後に質問を置く。

こうすると、AIは何をすべきか、どの情報を使うべきかを比較的理解しやすくなります。

実装上は、入力トークンと出力トークンの量を記録することも重要です。利用量が増えると、費用、応答速度、障害時の影響が見えてくるからです。

たとえば、毎回20ページ分の規程を丸ごと送る設計は、簡単に作れても効率が悪いかもしれません。本当に必要な段落だけを検索して渡すほうが、安く、速く、精度も上がる可能性があります。

また、同じ共通指示や同じ資料を何度も使う場合には、サービスによってはキャッシュ、つまり一時保存の仕組みを活用できる場合があります。これは、毎回同じ長文を処理し直す無駄を減らす考え方です。

ただし、キャッシュの有無、料金、保存範囲、情報保護の条件は提供元によって異なります。実際に導入するときは、必ず公式ドキュメントと契約条件を確認してください。

ここまでを一言でまとめるなら、AIの性能を引き出す鍵は、「たくさん情報を渡すこと」ではなく、「目的に合う情報を、整理して渡すこと」です。

では、今日のAI最新情報です。ここでは、日本時間2026年8月14日時点で、公式発表を確認できた情報から、今日のテーマであるトークンとコンテキストに関係の深い話題を四つ取り上げます。

一つ目。OpenAIは8月12日、企業でのAI活用に関する報告を公開しました。

発表では、先進的にAIを活用する企業ほど、AIを単なる質問応答ではなく、社内の文脈、業務ツール、再利用可能な手順と接続している傾向が示されています。

ここで重要なのは、「AIに会社の情報をつなぐ」ことです。ただ会話するだけではなく、顧客情報、社内ナレッジ、業務ルールといった適切なコンテキストを、権限管理のもとで渡すことで、AIは実務の支援から実行支援へ近づきます。

ただし、これはAIに自由な権限を与えるという意味ではありません。公式発表でも、権限、レビュー、ガバナンスの必要性が示されています。コンテキストが増えるほど便利になる一方、誤った情報へのアクセスや、機密情報の漏えいを防ぐ設計が重要になります。

二つ目。OpenAIは7月30日、GPT-5.6の価格性能に関する更新を発表しました。

この発表では、入力トークンと出力トークンの料金や、より効率的なコンテキスト管理に触れています。AIの実用化では、性能だけでなく、何トークンを読み、何トークンを出力し、それにどれだけの時間と費用がかかるかが重要です。

特に大量の文書を扱う業務では、不要な情報を毎回送らないこと、回答形式を指定して出力を必要以上に長くしないこと、軽い処理と難しい処理でモデルを使い分けことが、コストと品質の両方に影響します。

今日の学習テーマに直結するニュースですね。トークンは技術用語であると同時に、業務設計の単位でもあるのです。

三つ目。Anthropicは8月7日、Claude Fable 5における生物学関連の安全対策の改善を発表しました。

発表によると、一般的な健康や教育目的の質問で、過度に制限がかかるケースを減らしつつ、悪用の恐れがある分野では引き続き制御を行う方針です。

このニュースから学べるのは、AIは入力された言葉だけでなく、その質問が置かれた文脈も踏まえて安全性を判断しようとしている、という点です。

同じように見える質問でも、教育目的なのか、専門的な危険行為につながる可能性があるのかで、対応が変わる場合があります。ただし安全判定は完全ではなく、正当な質問が止められることも、逆に見逃しが起こる可能性もあります。だからこそ、AI提供企業は安全性と有用性のバランスを継続的に調整しています。

四つ目。Anthropicは7月24日、長時間にわたるエージェント型の作業、コーディング、専門業務の改善をうたうClaude Opus 5を発表しました。

エージェントとは、単に文章を返すだけでなく、計画を立て、必要に応じてツールを使い、複数の手順を進めるAIの仕組みです。

エージェント型の作業では、コンテキスト管理がさらに重要になります。途中まで何をしたのか。どのファイルを読んだのか。何を決定し、何が未確定なのか。こうした状態を適切に引き継がなければ、AIは同じ作業を繰り返したり、古い前提を進めたりする恐れがあります。

これからAIが複数ステップの仕事を担う場面が増えるほど、人間が「目的」「制約」「利用可能な情報」「確認が必要な境界」を明確にする力が重要になるでしょう。

ここで、今日の要点を整理します。

第一に、トークンはAIが文章を扱う基本単位です。単語や文字と完全には一致しません。日本語、数字、記号、コードなどで数は変わります。

第二に、コンテキストはAIが今の回答を作るときに参照できる情報の範囲です。質問だけでなく、過去の会話、指示、資料、検索結果、そして出力も含まれます。

第三に、長いコンテキストは便利ですが、情報を入れれば入れるほど正確になるとは限りません。大切な情報を整理し、目的に合わせて渡すことが重要です。

第四に、実務では、役割、目的、前提、資料、制約、出力形式を明確にすると、AIの回答品質が上がりやすくなります。

第五に、RAGのように必要な資料を検索してAIに渡す仕組みは有用ですが、検索ミス、古い文書、権限管理、情報漏えい、最終確認といった課題があります。

第六に、トークンはコストと速度にも関係します。長い入力と長い出力には、それだけ処理資源が必要です。

最後に、今日の1分理解チェックです。通勤中の方は、頭の中で答えてみてください。

第1問。トークンとは何でしょうか。

- A、AIが文章を扱う処理単位。
- B、AIが必ず覚えている単語帳。
- C、画像だけを数える単位。

答えはAです。トークンは、文章をAIが処理する細かな単位です。

第2問。コンテキストとは何でしょうか。

- A、AIが今の回答で参照できる情報の範囲。
- B、AIが永久に保存する記憶。
- C、AIの画面デザイン。

答えはAです。コンテキストは一時的な参照範囲であり、永久記憶とは限りません。

第3問。長い資料をAIに渡すとき、最も望ましい考え方はどれでしょうか。

- A、とにかく全文を貼り付ける。
- B、目的に必要な情報を整理し、出力形式も指定する。
- C、質問を短くするため、資料を一切渡さない。

答えはBです。必要な情報を、目的に合わせて構造化することが大切です。

第4問。社内文書を使ったAI回答で、特に重要な注意点は何でしょうか。

- A、AIの答えは必ず正しいので確認しない。
- B、個人情報や機密情報の扱い、権限、出典確認、人間のレビューを設計する。
- C、社内文書をすべて公開する。

答えはBです。

第5問。AIの利用コストを抑えるための考え方として適切なのはどれでしょうか。

- A、必要のない資料も毎回すべて送る。
- B、出力をできるだけ無制限に長くする。
- C、必要な情報だけを渡し、出力形式や長さを指定する。

答えはCです。

今日の講義はここまでです。

次回、Day

3では、「AIはなぜ間違えるのか。ハルシネーションと確率的な回答」をテーマに学びます。

AIは便利ですが、もっともらしい誤りを出すことがあります。なぜそれが起きるのか。どんな場面で注意すべきか。どうすれば誤りを見つけやすいか。今日学んだトークンとコンテキストの考え方ともつなげながら、実践的に解説します。

それでは、また次回お会いしましょう。

参考情報・一次情報

タイトル

From assistance to execution: How enterprises put AI to work

発行元

OpenAI

発表日

2026年8月12日

URL

<https://openai.com/index/how-enterprises-put-ai-to-work/>

タイトル

Advancing the price-performance frontier with GPT-5.6

発行元

OpenAI

発表日

2026年7月30日

URL

<https://openai.com/index/advancing-the-price-performance-frontier-with-gpt-5-6/>

タイトル

Improving Fable 5's biology safeguards

発行元

Anthropic

発表日

2026年8月7日

URL

<https://www.anthropic.com/news/improving-fable-5-s-biology-safeguards>

タイトル

Introducing Claude Opus 5

発行元

Anthropic

発表日

2026年7月24日

URL

<https://www.anthropic.com/news/claude-opus-5>