

AI Daily Academy

day 002 2026-08-15

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

AI Daily Academy、Week 1「AIの全体像」。Day 2のテーマは、「トークンとコンテキスト」です。

今日のテーマは、一見すると少し技術的に聞こえるかもしれませんが、でも、生成AIを仕事でも日常でも上手に使うために、とても大切な土台です。

なぜ、長い資料を一度に読ませると途中の内容を忘れたように見えるのか。なぜ、同じ質問でも、前に何を話したかによって答えが変わるのか。なぜ、AIサービスには文字数やファイル数の上限があるのか。

その答えの中心にあるのが、今日学ぶ「トークン」と「コンテキスト」です。

通勤中の30分で、専門用語をできるだけやさしくほどこきながら、明日から使える考え方まで身につけていきましょう。

それでは、始めます。

まずは前回、Day 1の復習です。

前は、「生成AIとLLM」について学びました。

生成AIとは、文章、画像、音声、プログラムのコードなど、新しいコンテンツを作り出すAIのことでした。そしてLLM、大規模言語モデルは、大量の文章を学習し、人間らしい言葉を扱えるようになったAIです。

LLMは、辞書や検索エンジンのように、正解を棚から取り出しているわけではありません。入力された言葉の流れを手がかりにして、「次に来そうな言葉」を確率的に予測し続けることで、文章を生成しています。

たとえば、「今日は暑いので、冷たい」と入力されたら、その後には「飲み物が欲しい」「ものを食べたい」といった言葉が続きやすい。LLMは、膨大な学習を通じて身につけた言葉どうしの関係を使いながら、もっとも自然らしい続き方を選んでいきます。

ただし、AIは人間のように会話のすべてを無制限に覚えているわけではありません。会話や資料のうち、いま処理できる範囲には限界があります。

そこで登場するのが、トークンとコンテキストです。

まず、「トークン」から見ていきましょう。

トークンとは、AIが文章を扱うときの、細かい部品、あるいは数える単位です。

ここで大切なのは、トークンは必ずしも「一文字」でも「一単語」でもない、ということです。

人間が文章を読むときは、「私は」「AIを」「学んでいます」のように、意味のまとまりとして捉えますよね。しかしAIは、文章をそのまま人間と同じようには扱いません。文字列を、あらかじめ決められた細かな部品に分け、その部品ごとに番号を割り当てて処理します。この部品がトークンです。

英語では、ひとつの単語がひとつのトークンになる場合もあります。しかし長い単語や珍しい単語は、複数の部分に分けられることがあります。

日本語では、単語の間にスペースがないため、さらに直感とずれることがあります。「人工知能」という四文字が、あるモデルではひとつのトークンに近い扱いになることもあれば、複数のトークンに分かれることもあります。「ありがとうございます」のようなよく使う表現は、効率よくまとまっている場合があります。一方、固有名詞、専門用語、珍しい記号の並び、プログラムのコードなどは、比較的多くのトークンを使うことがあります。

つまり、文字数が同じでも、消費するトークン数は同じとは限りません。

たとえば、短いメールでも、英数字、記号、URL、製品番号、表形式のデータが多いと、見た目以上にトークンを使う場合があります。逆に、自然な文章だけなら、比較的まとまりよく処理されることがあります。

このため、AIを使うときは「二千文字まで入力できます」と考えるよりも、「AIが処理できる部品の総量には上限がある」と考えるほうが、本質に近づけます。

では、AIはなぜ文章をトークンに分けるのでしょうか。

理由は、コンピューターが文字そのものではなく、数字を使って計算するからです。

AIは「会議」という文字を見て、そのまま理解しているわけではありません。「会議」に対応するトークンID、つまり数字の並びを受け取り、それぞれを数値のベクトルに変換して計算します。

ベクトルという言葉は、今は「意味や特徴を数字で表したもの」くらいに考えてください。

「会議」という言葉には、仕事、参加者、議題、議事録、予定、といった言葉とのつながりがあります。AIは、こうしたつながりを数値の関係として扱います。そして前後のトークンとの関係を計算して、文章全体の流れを読み取ろうとします。

ここで、もうひとつの重要語、「コンテキスト」です。

コンテキストとは、AIがいま参照しながら考えられる情報の範囲です。日本語では「文脈」と訳されます。

会話の文脈、と言いますよね。「それ、お願いします」とだけ言われても、何を指すのかは前の会話があれば分かりません。

たとえば、あなたがAIにこう話しかけたとします。

「来週の営業会議の議題を整理して」

AIが議題案を出します。

その後で、あなたが「三番目をもう少し短くして」と言う。

この「三番目」が何を意味するか、AIが分かるためには、先ほど出した議題案が、いまのコンテキストに入っている必要があります。

コンテキストは、AIにとっての作業机のようなものです。

机の上には、今の質問、これまでの会話、サービス側が最初に渡しているルール、アップロードした資料の一部、AIがツールを使って取得した情報、そしてAIがこれから生成する回答のための余白などが置かれています。

作業机が大きいほど、一般には長い会話や長い資料を一度に扱いやすくなります。これを「コンテキストウィンドウが大きい」と言います。

ウィンドウは窓という意味ですが、ここではAIが一度に見渡せる範囲、と考えると分かりやすいでしょう。

重要なのは、コンテキストには、あなたが入力する文章だけでなく、AIが出力する回答も含まれることが多い、という点です。

仮に、あるAIが合計十万トークンまで扱えるとします。その十万トークン全部を資料の入力に使えるとは限りません。システム側の指示、会話履歴、あなたの質問、検索結果やツールの結果、そしてAIが返す回答の分も必要です。

長い回答を求めるなら、その分だけ出力用の席を空けておく必要があります。

これは、通勤電車の座席に似ています。車両の定員が決まっているとき、大きな荷物をたくさん持ち込めば、人が座れるスペースは減ります。AIのコンテキストも同じです。長大な資料、長い会話履歴、細かな指示、たくさんの引用情報を一度に詰め込むほど、回答に使える余地は減っていきます。

ここで初心者の方が混同しやすいことを、はっきり分けておきましょう。

コンテキストは、AIの長期記憶ではありません。

ある会話でAIがあなたの好みやプロジェクト内容を理解しているように見えても、多くの場合、それは現在の会話画面に過去のやり取りが含まれているからです。その会話を閉じたり、新しいチャットを始めたりすると、同じ状態がそのまま続くとは限りません。

サービスによっては、ユーザー設定や保存メモリーの機能を提供している場合もあります。しかし、それも「すべてを無制限に覚える仕組み」ではありません。何が保存されるか、どの会話で使われるか、削除できるかは、各サービスの仕様と設定を確認する必要があります。

また、コンテキストと「学習」も別のものです。

あなたがAIに社内資料を貼り付けたからといって、その場でモデル全体が再訓練されるわけではありません。多くの場合、AIはその会話の範囲で資料を参照して答えているだけです。データが学習に使われるかどうかは、利用している製品、契約、設定によって異なります。仕事で機密情報を扱う場合は、利用規約だけでなく、会社の情報セキュリティ規程も必ず確認してください。

では、コンテキストが長ければ長いほど、常に良いのでしょうか。

答えは、必ずしもそうではありません。

長いコンテキストは便利です。しかし、資料をただ大量に入れば、AIが必ず正確になるわけではありません。

第一に、重要な情報が大量の文章の中に埋もれることがあります。人間でも、三百ページの資料を渡されて「大事な数字を見つけて」と言われたら、見落としが起こりえます。AIでも同じで、情報量が増えるほど、どの箇所を重視すべきかを明確に指示する必要があります。

第二に、古い指示と新しい指示が混ざる問題があります。会話を長く続けていると、最初の条件と途中で変わった条件が入り交じります。AIがどちらを優先すべきか曖昧になることがあります。

第三に、コストと速度です。多くのAI API、つまりプログラムからAIを呼び出す仕組みでは、入れたトークンと出したトークンの量が、料金や処理時間に影響します。コンテキストが長いほど、毎回読む量が増え、応答が遅くなったり、費用がかさんだりする可能性があります。

つまり、良いAI活用とは、「とにかく全部を入れること」ではありません。「いまの目的に必要な情報を、整理して渡すこと」です。

ここで、LLMが文脈を読む仕組みを、少しでも深掘りしてみましょう。

LLMには、前後のトークン同士の関係に注目する仕組みがあります。代表的な考え方が、アテンションです。

アテンションは、日本語にすると「注意を向けること」です。

たとえば、「田中さんは新製品を発表した。彼は質疑応答で…」という文章があったとします。「彼」が誰なのか判断するには、AIは前に出てきた「田中さん」に注意を向ける必要があります。

また、「売上は前年より増えたが、利益は減少した」と書かれていたら、「が」という接続の働きにも注意を向ける必要があります。

AIは、すべてのトークンを同じ重さで見るとはならず、いま生成しようとしている言葉に関係が深い部分へ、より注意を向けながら計算します。

ただし、AIが人間のように意味を完全に理解している、と言い切るのは正確ではありません。AIは言葉のパターンと関係を高度に処理していますが、現実世界を直接体験しているわけではありません。そのため、文脈に合ったもっともらしい誤り、いわゆるハルシネーションを起こすことがあります。

長い資料を与えたときほど、「資料のどこに書かれているか」「根拠の箇所を示して」「不明なら不明と答えて」と指示することが大切になります。

ここからは、コンテキストを使いこなす実践的な方法をお話しします。

一つ目は、目的を先に決めることです。

長い会議録をAIに渡す場合、「要約して」だけでは少し曖昧です。

「経営会議向けに、決定事項、未決事項、担当者、期限の四項目で整理してください」

「営業チーム向けに、顧客への影響と次のアクションだけを三百字でまとめてください」

「矛盾している発言があれば、発言者と該当箇所を挙げてください」

このように、何を探すのか、誰が使うのか、どの形式で出すのかを指定すると、AIは限られたコンテキストの中でも重要な箇所に注意を向けやすくなります。

二つ目は、資料を適切な大きさに分けることです。

たとえば、数百ページの規程集を扱う場合、全ページを一度に貼り付けるのではなく、章や見出しで分割します。そして、質問に関係しそうな部分を取り出してAIに渡します。

この方法は、RAG、ラグと呼ばれる仕組みの基本にもつながります。

RAGは、検索拡張生成の略です。少し難しい言葉ですが、考え方はシンプルです。

まず、社内文書やマニュアルを小さなまとまりに分けます。次に、質問に合いそうな部分を検索します。そして、見つけた部分だけをAIのコンテキストに入れて回答させます。

つまり、AIに全社フォルダを丸ごと覚えさせるのではなく、必要なページをその都度、作業机に置くイメージです。

この方法には、三つの利点があります。

必要な情報に絞れるため、回答の精度を上げやすいこと。毎回すべての文書を入れないため、コストと時間を抑えやすいこと。そして、どの文書を根拠にしたかを示しやすいことです。

三つ目は、回答のための余白を残すことです。

資料をぎりぎりまで詰め込むと、AIが十分な回答を生成できなかったり、途中で切れたりすることがあります。

実務では、「入力に使う上限」と「出力に確保する上限」を分けて設計します。

たとえば、詳細な分析レポートを作らせたいなら、先に出力用の余白を大きめに確保します。一方で、「この問い合わせを一文で分類して」といった作業なら、出力は短くてよいので、比較的多くの入力を扱えます。

四つ目は、会話をときどきリセットし、要約を引き継ぐことです。

長いプロジェクトをAIと進めるとき、何十往復もそのまま続けるよりも、節目で次のように依頼するほうが有効です。

「ここまでの決定事項、前提条件、未解決の論点を、次の会話に引き継ぐために千字以内で整理してください」

そして、新しい会話では、その要約と必要な資料だけを渡して始めます。

これは、人間のチームでも行う引き継ぎと同じです。会議の全発言を暗記するより、決定事項と宿題を整理した議事録のほうが役に立ちますよね。

身近な例で考えてみましょう。

一つ目は、旅行の計画です。

AIに「京都旅行を計画して」とだけ頼むと、一般的な提案になります。そこでコンテキストとして、「二泊三日」「祖父母と一緒に」「歩く距離は短め」「和食中心」「予算は一人五万円」「雨の場合の代替案が必要」といった条件を渡します。

するとAIは、単に観光地を列挙するのではなく、条件に沿った提案を作りやすくなります。

さらに、「初日の午前は新幹線で移動済み」「二日目の昼は予約済み」といった情報を会話の中で追加していけば、提案はより具体的になります。これがコンテキストを使った対話です。

二つ目は、家電の比較です。

「掃除機のおすすめを教えて」ではなく、「マンション、ペットあり、夜に使うので静音性重視、予算三万円、紙パック式は避けたい」と伝える。この条件がコンテキストです。

AIは条件が多いほど、個別事情に寄せた比較をしやすくなります。ただし、製品情報や価格は変わるため、最新情報が必要な場合は、AIに検索をさせるか、公式情報を確認する必要があります。

三つ目は、子どもの学習支援です。

教科書の一章と、子どもの回答例をAIに渡して、「小学六年生が理解できる言葉で、答えそのものは言わずにヒントを三段階で出してください」と頼む。ここでは教材、学年、回答例、指導方針がコン

テキストになります。

ただし、個人情報や成績情報を外部サービスへ入力する場合は、学校や家庭のルールに注意しましょう。

続いて、実務での実用例です。

最初は、カスタマーサポートです。

問い合わせ対応では、AIに製品マニュアル、返品規程、過去の対応方針を参照させ、回答案を作らせることがあります。このとき、すべてのマニュアルを無差別に渡すのではなく、問い合わせ内容に関係する製品ページと規程だけを検索して渡します。

そして、「規程に書かれていないことは推測しない」「回答案の後に参照した規程番号を示す」「返金や契約変更に関わるケースは人間にエスカレーションする」といったルールを加えます。

AIは下書きと情報整理を担い、最終判断は人間が行う。この役割分担が重要です。

次は、営業です。

商談前に、顧客企業の公開情報、自社の提案資料、過去の商談メモをAIに渡します。そして、「顧客の課題仮説を三つ」「確認すべき質問を五つ」「提案時に避けるべき断定を二つ」という形式で準備させます。

ここで気をつけたいのは、過去の商談メモが古い可能性です。AIは、古い情報と新しい情報を自動的に完全には見分けられません。資料に日付を付け、「最新の情報を優先する」と明示することが大切です。

三つ目は、法務や人事など、規程を扱う業務です。

社内規程について質問に答えるAIを作る場合、原文の根拠箇所を必ず提示する設計が有効です。「回答」「根拠となる規程名」「条番号」「判断できない点」を分けて出させます。

この形式にすると、利用者はAIの答えを鵜呑みにせず、原文を確認しやすくなります。特に法律、契約、労務、医療、金融など、高い正確性が求められる領域では、AIを最終決定者にしないことが原則です。

四つ目は、ソフトウェア開発です。

プログラムの不具合を調べる際、AIにコードの一部、エラーログ、実行環境、期待する動作を渡します。ここでも重要なのは、関係するコンテキストを過不足なく渡すことです。

コードだけを渡しても、どんなエラーが起きたのか分からなければ、AIは推測するしかありません。逆に、プロジェクト全体を全部貼り付けても、重要箇所が埋もれます。

「この関数」「このエラー」「この入力で再現」「期待結果はこれ」という四点をそろえると、AIはかなり役立つデバッグ補助になります。

では、実装例です。

ここでは、社内文書に質問できるシンプルなAIアプリを想像してみましょう。

基本の流れは五段階です。

第一に、文書を見出しや段落ごとに小さく分割します。これをチャンク分割と呼びます。

第二に、各チャンクに、文書名、作成日、部署、見出し、権限といった情報を付けます。これをメタデータと呼びます。

第三に、ユーザーから質問を受け取ります。

第四に、その質問に関連しそうなチャンクを検索します。

第五に、検索で見つかったチャンク、質問、回答ルールをまとめてAIへ渡し、回答を生成します。

プログラムの考え方を短く表すと、こうです。

「質問を受け取る。関連文書を検索する。検索結果と質問をAIへ渡す。根拠付きで回答させる。」

実装上のポイントは、トークン予算を最初から管理することです。

たとえば、AIに渡せる入力量の上限があるなら、検索で上位十件を見つけても、すべてをそのまま入れるとは限りません。重要度の高い順に並べ、出力用の余白を差し引きながら、入れられるところまで採用します。

また、文書の分割が大きすぎると、関係ない文章まで一緒に入り、トークンを無駄にします。小さすぎると、前後関係が失われます。

たとえば、就業規則なら一条だけで切るよりも、見出しと関連する数条をひとまとまりにするほうがよい場合があります。一方で、商品マニュアルなら、一つの機能説明と注意事項をひとつのチャンクにする、といった設計が考えられます。

正しい分割サイズは、文書の種類と質問の種類によって変わります。最初から完璧を狙うのではなく、実際の質問で試し、回答に必要な情報が欠けていないか、不要な情報が多すぎないかを確認して改善します。

さらに実装では、AIに次のようなルールを渡すとよいでしょう。

「提供された資料だけを根拠に回答すること。」

「資料に根拠がない場合は、分からないと回答すること。」

「各回答には、参照した文書名と見出しを付けること。」

「個人情報、機密情報、権限外の情報は出力しないこと。」

これらは、AIの賢さを上げる魔法の言葉ではありません。しかし、AIに期待する役割と境界線を明確にする、大切な設計です。

ここで、今日のAI最新情報です。2026年8月15日、日本時間時点で確認できた、テーマに関係する公式発表を五件ご紹介します。今日は、単なる新製品紹介ではなく、「トークン」「コンテキスト」「AIが出す情報の扱い方」とのつながりに注目してください。

一件目。Anthropicは2026年8月14日、Claudeが今後生成するテキストに、透かし、つまりウォーターマークを組み込む方針を説明しました。これは読者には見えない形で、Claudeが文章作成に関与した可能性を後から判定しやすくする仕組みです。発表によると、文章生成時に複数の自然な候補のなかから次のトークンを選ぶ過程を利用して、検出できるパターンを残します。追加トークンを発生させない設計だと説明されています。ただし、短い文章では検出が難しく、完全な書き換えで弱まるなどの限界もあります。今日のテーマとの関係は明確です。AIの文章は、トークンを一つずつ選んで作られます。その選択過程が、生成物の来歴確認にも利用され始めている、ということです。([anthropic.com](https://www.anthropic.com/news/claude-text-watermark))

二件目。Anthropicは2026年7月24日、Claude Opus 5を発表しました。発表では、利用者が「高い知能を優先するか」「トークンを節約して速さや費用を優先するか」を選べる努力設定に触れています。ここから初心者が押さえるべき点は、AIの品質、速度、コストの間にはトレードオフがあるということです。毎回もっとも重い設定を使うのではなく、メールの下書き、資料の分類、難しい分析といった仕事の種類に応じて、投入するトークンや計算量を変える発想が、実務ではますます重要になります。([anthropic.com](https://www.anthropic.com/news/claude-opus-5))

三件目。Google DeepMindは2026年7月21日、サイバーセキュリティ向けの軽量モデル、Gemini 3.5 Flash Cyberを発表しました。大規模なコードベースの脆弱性を調べる際、非常に大きなモデルを一度だけ呼ぶのではなく、軽量のモデルを複数回使い、複数の経路を調べて最終報告にまとめる考え方を示しています。これは、コンテキストや計算資源を一度に大量投入するだけが正解ではないことを表しています。小さな処理を分担し、必要な情報を統合する。実務のAIシステムでは、このような設計が増えています。なお、このモデルは限定的な提供から始める方針とされています。([deepmind.google](https://deepmind.google/blog/introducing-gemini-3-5-flash-cyber/))

四件目。OpenAIは2026年7月22日、米国の国立研究所や研究者との連携を通じて、科学研究へのAI活用を進める取り組みを発表しました。内容には、研究者へのモデル提供、スーパーコンピューターとの連携、生物科学やサイバー分野での評価などが含まれます。ここで重要なのは、AIに大量の科学情報を読ませれば自動的に発見が生まれる、という単純な話ではないことです。発表でも、研究者が問いを定め、方法を選び、出力を検証する中心的な役割を担うとされています。コンテキストを広げる技術と、人間による検証。この二つを組み合わせることが、専門領域でのAI活用の前提になります。([openai.com](https://openai.com/index/advancing-the-next-era-of-national-science/))

五件目。NVIDIAは2026年7月16日、日本のNoetra社と連携し、製造、物流、医療などでの活用を想定した、物理AI向けの国家規模AI基盤に関する発表を行いました。発表では、日本のFRONTiaプロジェク

トの計算基盤として、マルチモーダル基盤モデル、つまり文章だけでなく画像や音声なども扱うAIモデルの開発を支える計画が示されています。ここでのポイントは、AIの進化はモデルの性能だけでなく、どれだけ多くのトークンや画像、映像、センサー情報を安全かつ低コストに処理できるかという、計算基盤にも支えられていることです。私たちが日常的にAIへ短い質問を投げかけられる背景にも、大規模なインフラがあります。([nvidianews.nvidia.com](https://nvidianews.nvidia.com/_gallery/download_pdf/6a588fd83d6332d9f6252f77/))

それでは、今日の要点を整理します。

一つ目。トークンは、AIが文章を処理する細かな単位です。文字数や単語数と完全には一致しません。

二つ目。コンテキストは、AIがその時点で参照できる情報の範囲です。質問、会話履歴、資料、システム指示、そして回答用の余白も含まれます。

三つ目。コンテキストは長期記憶そのものではありません。新しい会話や別のサービスで、同じ情報がそのまま使われるとは限りません。

四つ目。長い資料を扱うときは、全部を詰め込むよりも、目的を明確にし、必要な情報を検索して渡すほうが効果的です。

五つ目。実務では、文書の分割、検索、根拠の提示、出力用トークンの確保、人間による確認が重要です。

では最後に、1分理解チェックです。

第一問。トークンは必ず一文字、または一単語と一致するでしょうか。

答えは、いいえです。トークンはAI用の分割単位であり、文字数や単語数とは一致しないことがあります。

第二問。コンテキストとは何でしょうか。

答えは、AIがいま参照して回答を作るために使える、情報の範囲です。

第三問。長い資料をAIに渡すとき、最もよい方法は何でしょうか。「全部を無条件に貼り付けること」でしょうか。それとも、「目的に関係する部分を選び、回答形式も指示すること」でしょうか。

答えは後者です。必要な情報を整理して渡すことが、精度、速度、コストのバランスにつながります。

第四問。AIが会話内容を覚えているように見えるとき、それは必ずモデルが学習し直されたことを意味するでしょうか。

答えは、いいえです。多くの場合、その会話履歴がコンテキストとして渡されているためです。

第五問。AIの回答が規程や契約に関わる場合、どう使うのが適切でしょうか。

答えは、根拠箇所を示させ、人間が原文を確認し、最終判断を人間が行うことです。

今日の講義はここまでです。

次回、Day 3では、「プロンプトの基本」を学びます。

AIへの指示文であるプロンプトは、単に質問を書く欄ではありません。目的、前提、制約、出力形式を伝えるための設計図です。

今日学んだトークンとコンテキストの考え方を土台にすると、なぜ「良い指示」がAIの回答を変えるのかが、より深く理解できます。

それでは、また次回。AI Daily Academyでした。

参考情報・一次情報

タイトル

How Claude 's text watermark works

発行元

Anthropic

発表日

2026年8月14日

URL

<https://www.anthropic.com/news/claude-text-watermark>

タイトル

Introducing Claude Opus 5

発行元

Anthropic

発表日

2026年7月24日

URL

<https://www.anthropic.com/news/claude-opus-5>

タイトル

Introducing Gemini 3.5 Flash Cyber

発行元

Google DeepMind

発表日

2026年7月21日

URL

<https://deepmind.google/blog/introducing-gemini-3-5-flash-cyber/>

タイトル

Advancing the next era of national science

発行元

OpenAI

発表日

2026年7月22日

URL

<https://openai.com/index/advancing-the-next-era-of-national-science/>

タイトル

Japan Government, Industrial Leaders and NVIDIA Launch the World ' s First National AI Infrastructure

発行元

NVIDIA

発表日

2026年7月16日

URL

https://nvidianews.nvidia.com/_gallery/download_pdf/6a588fd83d6332d9f6252f77/