

AI Daily Academy

day 006 2026-08-17

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

この音声はAI生成音声でお届けします。

AI Daily Academy、Week 1「AIの全体像」。Day 6のテーマは、「主要モデルの違い」です。

おはようございます。あるいは、こんにちは。

通勤や移動の時間に、AIを少しずつ体系的に学ぶAI Daily Academyです。

ここ数日、私たちはAIの内部で起きていることを、順番に見てきました。今日はそれらをつながながら、「結局、AIモデルにはどんな種類があり、何を基準に使い分ければよいのか」を学びます。

ChatGPT、Gemini、Claude、画像生成AI、音声AI。名前はたくさん聞くけれど、何がどう違うのかは分かりにくいですね。

今日のゴールはシンプルです。

モデル名を暗記することではありません。

「文章ならこの種類」「大量処理ならこの種類」「画像も扱うならこの種類」「社内データを安全に使うならここを確認する」と、自分の仕事や目的に合わせて、モデルを選ぶ視点を身につけることです。

では、始めましょう。

まず、前回の復習です。

Day 3では、Embedding、つまり埋め込み表現を学びました。文章や画像などを、意味の近さを計算できる数字の並び、ベクトルに変換する技術でした。

たとえば、「有給休暇の申請方法」と「休みを取りたい」という文章は、使われている言葉が違っていても意味は近いですね。Embeddingを使うと、その近さを数字として扱えます。これが社内検索や、RAG、つまり社内文書を参照して答えるAIの土台になります。

Day 4では、学習と推論の違いを確認しました。

学習は、AIモデルを作る段階です。大量のデータを使い、パラメータ、つまりモデル内部の調整つまみを更新します。時間も計算資源も大きく必要です。

一方、推論は、完成したモデルを使う段階です。私たちがチャットに質問を入力して、返答を受け取る。これが推論です。

そしてDay 5では、ハルシネーションを扱いました。

ハルシネーションとは、AIがもっともらしいけれど事実ではない内容を生成してしまうことです。

ここで大事ななのは、AIは検索結果をそのまま読む機械でも、事実を完全に記憶した辞書でもない、ということです。基本的には、入力された文脈をもとに、「次に来そうな言葉」を予測して文章を作っています。

だからこそ、重要な業務で使うときは、情報源を与える、出典を確認する、計算は別の仕組みで検証する、人が最終判断する、といった設計が必要になります。

今日の「主要モデルの違い」は、この3日間の学びの続きです。

モデルによって、得意な入力、得意な出力、速さ、価格、扱える情報量、そしてハルシネーションへの対策方法が違います。

では、今日の基礎講義に入りましょう。

まず、そもそも「AIモデル」とは何でしょうか。

一言で言えば、入力を受け取り、何らかの出力を作るために学習された計算の仕組みです。

文章を入れて文章を返すモデル。

画像を見て説明するモデル。

音声を文字にするモデル。

文章から画像を作るモデル。

そして、文章や画像をベクトルに変換するEmbeddingモデル。

すべて「モデル」ですが、役割は同じではありません。

初心者の方は、まず次の6種類に分けると理解しやすくなります。

1つ目は、汎用の言語モデルです。

これは、会話、要約、翻訳、文章作成、アイデア出し、質問応答などを幅広くこなすモデルです。

多くの方が「生成AI」と聞いて最初に思い浮かべるのが、このタイプでしょう。プロンプト、つまり指示文を入力すると、自然な文章を返してくれます。

たとえば、「会議メモを3行で要約して」「このメールをやわらかい表現に直して」「新サービスの企画案を5つ出して」といった仕事に向いています。

ただし、汎用モデルは、何でもできるように見えても、すべてにおいて最適とは限りません。大量の短い分類作業なら、もっと小さく速いモデルのほうが良い場合があります。画像や図表の理解が中心なら、マルチモーダルモデルを選んだほうがよい場合もあります。

2つ目は、推論モデル、あるいは思考を強めたモデルです。

推論とは、単に知識を出すだけでなく、条件を整理し、途中の手順を考え、複数の選択肢を比較して答えを導く能力です。

たとえば、「予算は100万円、納期は3か月、担当者は2人。この条件でプロジェクト計画を作って」といった複数条件の整理。あるいは、プログラムのバグの原因分析、複雑な表の読み取り、数理問題、契約文書の論点整理などが該当します。

ここで注意したいのは、推論モデルが「必ず正しい答えを出すモデル」ではないことです。

考える時間や計算量を多く使うことで、難しい問題への対応力を高める設計ですが、誤った前提を与えれば、誤った結論に向かうことがあります。また、外部の最新情報を持っているわけではありません。

大事な判断では、モデルの回答を結論として受け取るのではなく、検討材料として使うことが基本です。

3つ目は、小型モデルです。

小型モデルは、一般に、大型モデルよりも軽く、速く、低コストで動かしやすいモデルです。性能を必要な範囲に絞り、特定の処理を大量にこなすことに向いています。

たとえば、ECサイトのレビューを「好意的・中立・否定的」に分類する。問い合わせメールを部署別に振り分ける。数万件の文章から製品名を抜き出す。こうした仕事です。

1件ごとの深い相談に最高性能の大型モデルを使うのは合理的でも、100万件の問い合わせを分類するなら、速度とコストが重要になります。

ここで覚えておきたいのは、「大きいモデルが常に正解ではない」ということです。

AI導入では、モデルの能力だけでなく、1件あたりの料金、応答までの時間、同時に処理できる件数、運用のしやすさまで含めて選びます。

4つ目は、マルチモーダルモデルです。

モーダルとは、情報の形式のことです。

テキスト、画像、音声、動画、表、PDFなど、それぞれが異なるモダリティです。

マルチモーダルモデルは、複数の形式を扱えます。

たとえば、レシートの写真を読み取って経費の候補を作る。グラフを含む報告書を読んで要点をまとめる。製品写真から説明文を作る。録音した会議音声を文字起こしし、さらに要約する。こうした処理ができます。

人間の仕事では、文章だけで完結する場面は意外に少ないですよ。表計算、画面のスクリーンショット、現場写真、図面、音声、動画。実務に近づくほど、複数形式を扱う力が重要になります。

ただし、画像を見られるモデルでも、細かい数字や小さな文字を確実に読めるとは限りません。特に帳票や契約書、医療画像、図面のように誤りの影響が大きいものでは、専用のOCR、つまり文字認識の仕組みや、人による確認を組み合わせる必要があります。

5つ目は、Embeddingモデルです。

これはDay 3の復習ですね。文章を作るのではなく、意味を表すベクトルを作るモデルです。

ユーザーが質問したとき、社内規程、過去の議事録、製品マニュアルなどから、意味の近い文章を探す。そのために使われます。

言語モデルが「答えを書く担当」だとすれば、Embeddingモデルは「意味で探す担当」です。

RAGでは、まずEmbeddingで関連文書を探し、その文書を言語モデルに渡し、根拠に沿って回答させます。つまり、Embeddingモデルと生成モデルは、競争相手ではなく、役割分担する仲間です。

6つ目は、特化型モデルです。

これは、ある用途に強く最適化されたモデルです。

代表例は、コード生成モデル、音声認識モデル、音声合成モデル、画像生成モデル、画像編集モデル、OCRモデル、翻訳モデル、さらにはロボット制御向けのモデルなどです。

たとえば、議事録作成において、「音声を文字にする」部分は音声認識モデルが担当します。その文字起こしを読みやすく要約する部分は言語モデルが担当します。読み上げ音声を作るなら音声合成モデルが担当します。

ひとつの万能モデルだけですべてを済ませるのではなく、仕事の工程ごとに得意なモデルを組み合わせる。この考え方が、実務ではとても重要です。

ここからは、モデルの違いを生む仕組みを見ていきましょう。

モデルの性能差は、単純に「賢いか、賢くないか」だけでは決まりません。

まず、モデルの規模があります。

一般に、より多くのパラメータを持つモデルは、複雑なパターンを表現しやすい傾向があります。パラメータとは、学習によって調整される内部の数値です。

ただし、パラメータ数が多ければ、必ず実務で勝つわけではありません。

モデルの設計。学習に使ったデータ。学習後の調整。推論時に使える計算量。ツールを使えるか。長い文書を扱えるか。こうした要素が組み合わさって、実際の使い勝手が決まります。

次に、コンテキストウィンドウという違いがあります。

コンテキストウィンドウとは、AIが一度に参照できる情報量のことです。会話の履歴、アップロードした文書、指示文、検索で見つけた資料などを、どこまで一緒に読めるかを表します。

コンテキストが長いモデルは、長文の報告書、複数の契約書、長い会議ログ、ソースコード一式などを扱いやすくなります。

ただし、長い文書を入力できることと、文書のすべてを完璧に理解できることは別です。

長文を扱うときほど、「何をしてほしいか」を明確にする必要があります。たとえば、「この資料の結論だけを要約して」よりも、「この資料から、売上減少の原因、根拠となるページ、来月までに必要な対応を表にして」のほうが、期待する出力に近づきやすくなります。

もう一つ、重要なのがツール利用です。

AIモデルそのものは、文章を生成する仕組みです。しかし、外部の検索、データベース、電卓、カレンダー、社内システム、プログラム実行環境などを使えるようにすると、できる仕事が大きく広がります。

たとえば、「今月の売上データを見て、先月比で下がった商品を教えて」という依頼を考えてみましょう。

モデルが売上データを持っていないければ、当然、正確には答えられません。そこでAIがデータベースを検索し、必要な数値を取得し、計算ツールで比較し、文章で説明する。こうした流れにします。

このとき、モデルは単独で正解を知っているわけではありません。必要に応じて、外部の正しい情報を取りに行き、作業を組み立てているのです。

これが、最近よく聞く「AIエージェント」の基本的な考え方です。

エージェントとは、目標に向けて、情報を集め、計画し、ツールを使い、結果を確認するAIシステムを指します。

ただし、エージェント化すれば自動的に安全になるわけではありません。外部システムを操作できるAIには、権限管理、操作前の承認、ログ保存、誤操作時の停止方法が必要です。

メール送信、発注、顧客データの更新、コードの本番反映などは、特に人の承認を残す設計が重要です。

では、身近な具体例で使い分けを考えてみましょう。

まず、旅行の計画です。

「京都へ1泊2日で行きたい。予算は5万円。歴史的な場所を中心に、移動が少ないプランを作って」と頼むなら、汎用の言語モデルでも、かなり役立つたたき台を作れます。

一方で、営業時間、料金、運休情報、予約の空き状況は変わります。こうした最新性が必要な部分は、検索や公式情報を参照できる仕組みが必要です。

つまり、旅程のアイデア出しには言語モデル。

最新の事実確認には検索。

地図や写真を理解するならマルチモーダル機能。

このように役割が分かります。

次に、家計管理です。

レシートを撮影して内容を読み取るなら、画像理解やOCRが活躍します。読み取った品目を食費や日用品に分類するなら、小型の言語モデルでも十分な場合があります。月ごとの支出を合計するなら、計算機能や表計算ソフトに任せるのが安全です。そして「外食費が増えた理由を推測して」と聞く段階で、言語モデルが説明役になります。

ここでも、ひとつのモデルだけに任せていません。

最後に、学習支援です。

問題文を見て解説するなら、推論モデルが向くことがあります。ノートの写真を読み取るならマルチモーダルモデル。用語集から似た概念を探すならEmbedding。自分の声で話した内容を復習ノートにするなら、音声認識と要約モデルです。

AIはひとつの魔法の箱ではなく、用途ごとに道具を使い分ける工具箱だと考えると、理解しやすいでしょう。

続いて、実務での実用例です。

一つ目は、社内ナレッジ検索です。

人事規程、経費精算ルール、営業資料、過去の提案書。会社には多くの文書があります。しかし、必要な情報を探すだけで時間がかかります。

ここで中心になるのは、Embeddingモデルです。文書を意味ベクトルにして検索し、質問に近い規程や資料を見つけます。そして言語モデルが、その根拠をもとに回答文を作ります。

実務では、「回答だけを出す」よりも、「根拠になった文書名と該当箇所も出す」設計が重要です。これにより、利用者が確認できます。ハルシネーション対策にもなります。

二つ目は、カスタマーサポートです。

問い合わせへの回答文を作るなら、汎用言語モデルが役立ちます。ただし、すべてを最高性能のモデルで処理する必要はありません。

まず小型モデルで、問い合わせを「配送」「返品」「請求」「障害」などに分類する。次に、Embedding検索で関連するFAQを探す。最後に、難しい問い合わせだけを高性能なモデルに渡して、回答案を作る。そして返金や契約変更などの重要操作は、人が確認する。

こうすると、コストと品質、安全性のバランスを取りやすくなります。

三つ目は、営業資料の作成です。

顧客との会話を音声認識で文字起こしし、言語モデルで要約します。顧客の課題、決定事項、次のアクション、担当者、期限を抽出します。そのうえで、過去の提案書をEmbeddingで検索し、近い事例を参照します。必要に応じて、図表や製品写真もマルチモーダルモデルで読み取ります。

この一連の流れを見ると、AI活用で本当に重要なのは、「どのモデルが最強か」ではなく、「業務のどこに、どのモデルを置くか」だと分かります。

四つ目は、ソフトウェア開発です。

コード生成に強いモデルは、関数の下書き、テストコード作成、エラーの原因調査、既存コードの説明などを支援できます。

ただし、コードを生成できることと、本番環境で安全に動くことは別です。自動テスト、レビュー、権限管理、変更履歴、段階的な公開が必要です。

AIには「下書き担当」「調査担当」「テスト案の作成担当」を任せ、人には「設計の責任者」「最終レビュー担当」を任せる。この分担が現実的です。

ここで、モデル選びのための実践的な5つの質問を紹介します。

新しいAIツールやモデルを検討するときは、まず次の順で考えてください。

第1に、入力は何か。

文章だけですか。PDFですか。表ですか。画像ですか。音声ですか。複数あるなら、マルチモーダル対応が必要かもしれません。

第2に、出力は何か。

チャット回答ですか。分類ラベルですか。検索結果ですか。コードですか。音声ですか。出力が決まると、必要なモデルの種類が見えてきます。

第3に、正確性はどの程度必要か。

アイデア出しなら、多少の誤りは人が直せます。しかし、契約、医療、法務、会計、人事評価、対外公表では、根拠確認と人の判断が欠かせません。

第4に、量と速さはどの程度か。

1日に10件の相談を丁寧に処理するなら高性能モデルでもよいでしょう。1日に10万件の文書を分類するなら、小型モデルやルールベース、バッチ処理も検討対象です。

第5に、データをどこまで渡せるか。

顧客情報、未公開資料、個人情報扱うなら、利用規約、保存方針、学習利用の有無、アクセス権、監査ログ、社内ルールを確認する必要があります。

モデル比較表の順位だけで選ばず、この5つを先に整理する。これが、失敗しにくいAI導入の出発点です。

ここで、簡単な実装例を見てみましょう。

テーマは、「社内規程に答えるAI」です。

この仕組みでは、最初に社内規程を小さな文章のまとまりに分けます。次に、それぞれをEmbeddingモデルでベクトル化して保存します。

社員から「出張時の宿泊費の上限はいくらですか」と質問が来たら、その質問もベクトル化します。保存済みの規程の中から、意味が近い箇所を探します。

そして、見つかった規程の文章を、言語モデルに渡します。ここで大切なのは、単に「答えて」と頼むのではなく、「以下の規程だけを根拠に回答してください。根拠がなければ、分からないと答えてください」と指示することです。

資料上の簡略化した疑似コードは、次のようなイメージです。

```
```python
```

```
question = "出張時の宿泊費の上限はいくらですか"
```

```
hits = vector_search(question, top_k=3)
```

```
prompt = ""
```

以下の社内規程だけを根拠に回答してください。

根拠が見つからない場合は、推測せず「規程内では確認できません」と教えてください。

回答には、参照した規程名を付けてください。

```
""
```

```
answer = generate_text(prompt, context=hits)
```

```
...
```

ここで重要なのは、コードの細部ではありません。

「検索する役」と「回答を書く役」を分けていること。

「根拠がなければ推測しない」と明示していること。

「参照元を出す」ようにしていること。

この3点です。

さらに実務では、回答の評価も必要です。

よくある質問を50件ほど用意し、正しい規程を参照できたか、回答に誤りがないか、回答できないときに無理に作り話をしていないかを確認します。

AI導入は、一度作って終わりではありません。

実際の利用ログを見ながら、検索対象の文書を整え、プロンプトを改善し、必要ならモデルを変える。この継続的な改善が品質を左右します。

```

```

ここからは、2026年8月17日時点で押さえておきたい、直近のAI最新情報です。

今日は「主要モデルの違い」というテーマに合わせて、性能の一点勝負ではなく、用途別・効率別・入力形式別にモデルが分化している流れに注目します。

1件目です。Googleは7月21日、Gemini 3.6 Flash、Gemini 3.5 Flash-Lite、Gemini 3.5 Flash

Cyberを発表しました。3.6 Flashはコーディング、知的作業、マルチモーダル処理を担う実用的な主力モデルとして位置づけられています。一方、Flash-Liteは、低コスト・低遅延で大量処理を行う用途を狙っています。これは今日の講義で扱った、「すべてを最大モデルで処理しない」という考え方の具体例です。大量の文書処理や問い合わせ分類では、速度と費用もモデル選定の重要な基準になります。  
。([blog.google](https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-6-flash-3-5-flash-lite-3-5-flash-cyber/))

2件目です。Metaは7月9日、マルチモーダル推論モデルのMuse Spark 1.1と、開発者向けMeta Model APIの公開プレビューを発表しました。公式発表では、ツール利用、コンピューター操作、コーディング、複数のサブエージェントの連携を強化したと説明されています。ここから見えるのは、AIモデルが「答えを返すチャット」から、情報を集め、作業を分担し、ツールを使うシステムへ広がっていることです。ただし、実務で外部操作を任せるなら、人の承認と権限管理が重要になる点は変わりません。  
([ai.meta.com])(<https://ai.meta.com/blog/introducing-muse-spark-meta-model-api/>)

3件目です。Mistral AIは7月8日、ロボット向けのナビゲーションモデル、Robostral Navigateを発表しました。これは、テキストだけではなく、単眼カメラの画像と自然言語の指示をもとに、ロボットの移動を支援するモデルです。今日学んだ特化型モデルの分かりやすい例ですね。汎用チャットAIとは異なり、「現実空間でどこへ動くか」という限定された課題に最適化されています。AIの進化は、汎用モデルの大型化だけでなく、現場の仕事に合わせた専門モデルの発展でも進んでいます。  
([mistral.ai])([https://mistral.ai/news/robostral-navigate/?utm\\_source=openai](https://mistral.ai/news/robostral-navigate/?utm_source=openai))

4件目です。OpenAIは8月1日、数学と理論計算機科学における10件の成果を公表しました。公式発表によると、次世代モデルの内部版を用いて、長年未解決だった問題に対する結果や大きな進展を示し、人間が論文原稿を整え、さらに形式検証にも取り組んだとされています。これは一般的なビジネス利用とは少し離れたニュースに見えるかもしれませんが。しかし、推論モデルの価値を考えるうえでは重要です。単に文章を滑らかに書く能力だけでなく、仮説を立て、検討し、検証可能な形に近づける能力が、研究や専門業務で注目されていることを示しています。もっとも、研究成果の評価は専門家による検証が不可欠であり、AIの出力をそのまま確定的な事実として扱うべきではありません。  
([openai.com])(<https://openai.com/index/ten-advances-in-mathematics/>)

## 今日のニュースからのまとめです。

モデルの進化は、「より大きく、より賢く」だけではありません。

高速・低価格なモデル。

画像や音声も扱うモデル。

コードやセキュリティに特化したモデル。

ロボットを動かすモデル。

長い手順を実行するエージェント向けモデル。

用途に応じた分化が、ますます進んでいます。

---

では、今日の要点を整理しましょう。

第一に、AIモデルには役割の違いがあります。

幅広い文章作業には、汎用言語モデル。

複雑な条件整理や問題解決には、推論モデル。

大量で単純な処理には、小型モデル。

画像、音声、動画、PDFも扱うなら、マルチモーダルモデル。

意味検索には、Embeddingモデル。

音声、画像、コード、OCR、ロボット制御には、特化型モデルです。

第二に、モデル選びでは、性能ランキングだけを見ないことです。

入力の種類。

必要な出力。

正確性の要求。

処理量と速度。

データの安全性。

この5つを整理してから選ぶと、AIを実務に結びつけやすくなります。

第三に、実務では複数モデルの組み合わせが基本です。

Embeddingで探す。

言語モデルで説明する。

計算ツールで数値を確かめる。

音声認識で会話を文字にする。

人が最終確認する。

こうした分業によって、AIはより安全で役立つ仕組みになります。

第四に、モデルは万能ではありません。

推論モデルでも誤ることがあります。

マルチモーダルモデルでも画像を誤読することがあります。

長文を読めても、重要箇所を見落とすことがあります。

だから、重要な情報には根拠を付ける。

重要な操作には承認を入れる。

重要な判断は人が担う。

これがAI活用の基本姿勢です。

---

最後に、1分理解チェックです。

移動中の方は、頭の中で答えてみてください。

第1問。

社内規程から、社員の質問に近い箇所を意味で探す役に向いているのは、何モデルでしょうか。

答えは、Embeddingモデルです。

第2問。

毎月100万件の短い問い合わせを、担当部署ごとに振り分ける業務で、特に重視すべきなのは何でしょうか。最高性能だけでしょうか。

答えは、性能だけではありません。処理速度、コスト、同時処理数、必要十分な精度を重視します。小型モデルが適する可能性があります。

第3問。

写真に写ったレシートを読み取り、支出内容を要約するには、どんなモデルや仕組みの組み合わせが考えられるでしょうか。

答えは、画像理解またはOCRで文字を読み取り、言語モデルで内容を整理する組み合わせです。合計金額の計算は、表計算や計算ツールで検証するとより安全です。

第4問。

AIが検索、メール送信、発注などの外部ツールを使えるようになったとき、なぜ人の承認や権限管理が必要なのでしょう。

答えは、AIが誤った判断や誤解した指示に基づいて、実際のシステムを操作する可能性があるからです。特に取り消しにくい操作は、人の確認を残すべきです。

第5問。

長い文書を入力できるモデルなら、その内容を必ず完全に理解できるでしょうか。

答えは、いいえです。入力できることと、正確に要点を把握できることは別です。目的を明確に指示し、根拠を確認する必要があります。

---

次回、Day 7のテーマは、「AIを使うための基本操作」です。

モデルの違いを理解した次は、実際にAIへどう依頼すれば、期待に近い答えを得られるのかを学びます。

プロンプトとは何か。

良い指示と曖昧な指示はどう違うのか。

AIに役割、目的、条件、出力形式をどう伝えるのか。

明日からすぐ使える、AIとの話し方の基本を扱います。

それでは、今日もよい一日を。

## 参考情報・一次情報

### 1. タイトル

Introducing Gemini 3.6 Flash, 3.5 Flash-Lite, and 3.5 Flash Cyber

発行元

Google

発表日

2026年7月21日

URL

<https://blog.google/innovation-and-ai/models-and-research/gemini-models/gemini-3-6-flash-3-5-flash-lite-3-5-flash-cyber/>

### 2. タイトル

Introducing Muse Spark 1.1

発行元

Meta

発表日

2026年7月9日

URL

<https://ai.meta.com/blog/introducing-muse-spark-meta-model-api/>

### 3. タイトル

Robostral Navigate: single-camera AI navigation

発行元

Mistral AI

発表日

2026年7月8日

URL

<https://mistral.ai/news/robostral-navigate/>

## 4. タイトル

Ten advances in mathematics and theoretical computer science

発行元

OpenAI

発表日

2026年8月1日

URL

<https://openai.com/index/ten-advances-in-mathematics/>