

AI Daily Academy

day 005 2026-08-14

通勤用音声教材の文字版 - 最新情報の参照元は末尾に掲載

AI Daily Academy

Week 1「AIの全体像」／Day 5「ハルシネーション」

この音声はAI生成音声でお届けします。

1. オープニング

おはようございます。AI Daily Academy、主任講師の時間です。

Week 1「AIの全体像」、Day 5のテーマは、**ハルシネーション**です。

ハルシネーション。日本語では「幻覚」と訳されることがあります。ただし、AIが人間のように何かを見間違えている、という意味ではありません。生成AIが、もっともらしい言葉で、事実ではない内容や、根拠のない内容を出力してしまう現象のことです。

たとえば、存在しない本のタイトルを紹介する。実在しない法律の条文を引用する。会議で言われていない発言を議事録に補う。あるいは、知っているはずのない最新情報を、堂々と断定する。こうしたことが起こり得ます。

便利なAIを、仕事でも生活でも安心して使うには、ハルシネーションを「たまに起こる失敗」と軽く見るのではなく、AIの性質として理解することが大切です。

今日のゴールは三つです。

一つ目。なぜAIがハルシネーションを起こすのかを、直感的に説明できるようになること。

二つ目。AIの回答を、鵜呑みにせず、かといって怖がりすぎずに使う方法を身につけること。

三つ目。実務で使える、ハルシネーション対策の基本形を持ち帰ることです。

通勤中の30分、肩の力を抜いて聞いてください。

2. 前回の復習

まず、Day 2からDay 4までを短く振り返ります。

Day 2では、**トークンとコンテキスト**を学びました。

AIは文章を、人間のように一文ずつ意味として読んでいるわけではありません。文字や単語のまとまりであるトークンとして扱い、その場で参照できる情報、つまりコンテキストをもとに、次に続くトークンを予測します。

ここで重要なのは、AIが会話の外にある事実を、いつでも自由に確認しているわけではないことです。入力された情報、あらかじめ持つ知識、接続された検索やデータベースなど、与えられた範囲で答えます。

Day 3では、**Embeddingとベクトル**を扱いました。

文章、画像、商品、顧客の問い合わせなどを、意味の近さで扱える数字の並びに変換する技術です。これによって、「この質問に近い過去の規程は何か」「この問い合わせに似た事例は何か」といった検索が可能になります。

Day 4では、**学習と推論**を見ました。

学習は、膨大なデータから言葉のパターンを身につける段階。推論は、学習済みのモデルが、今の質問に対して答えを生成する段階です。

そして今日のハルシネーションは、この三つと深く関係します。

AIはトークンを予測して答えを作る。コンテキストに正確な情報がなければ、正解を保証できない。意味検索で似た資料を見つけても、その資料が本当に正しいか、最新版か、質問に適切かは別問題です。そして推論の場面では、もっともらしい文章を滑らかに続けられること自体が、誤りを生む条件にもなります。

ここまでの流れを一言で言うと、こうです。

AIは「真実を知っている装置」ではなく、「与えられた条件のもとで、もっともらしい次の言葉を生成する装置」である。

この見方が、今日の土台になります。

3. 今日の基礎講義：ハルシネーションとは何か

では、ハルシネーションを定義しましょう。

AIにおけるハルシネーションとは、**出力内容が事実、入力資料、指定条件、または論理的な制約と一致していないにもかかわらず、もっともらしく生成されること**です。

ポイントは、「間違った答え」より少し広い概念だということです。

たとえば、計算ミスも間違いです。しかしハルシネーションで問題になりやすいのは、AIが根拠を持っているように見せながら、存在しない根拠まで作ってしまうことです。

代表的には四つあります。

一つ目は、**事実の捏造**です。

「この会社は2021年に設立されました」と答えたが、実際は存在しない会社だった。

「この論文は有名な学会で発表されました」と言ったが、論文も学会発表も存在しない。

こうしたタイプです。

二つ目は、**引用や出典の捏造**です。

AIに「根拠も付けて」と依頼すると、書籍名、論文名、URL、法令名、判例番号のようなものを整った形式で返すことがあります。しかし、形式が整っていることと、出典が実在することは別です。

三つ目は、**入力文書の読み違い、または補完しすぎ**です。

会議メモに書かれていない決定事項を、「文脈からするとこうでしょう」と補って議事録に入れてしまう。契約書の曖昧な表現を、断定的に解釈してしまう。要約を頼んだのに、原文にない背景説明を足してしまう。これは実務で特に注意が必要です。

四つ目は、**制約違反**です。

「資料に書いてあることだけで教えてください」と頼んだのに、AIが一般知識を混ぜる。

「わからない場合は、わからないと教えてください」と言ったのに、推測で答える。

「日本語で200文字以内」と指定したのに、条件を守れない。

これも広い意味で、期待した事実や条件から外れた出力です。

ここで、誤解しやすい点を一つ整理します。

ハルシネーションは、AIが意図的に嘘をついているわけではありません。

AIには通常、「騙そう」という意図はありません。AIは、今ある文脈から、次に自然に続きそうな表現を選び続けています。質問が具体的で、答えの形が想像しやすく、しかも正解となる情報が手元にないとき、AIは空欄を埋めるように、自然な文章を生成しやすくなります。

人間にたとえるなら、知らないことを聞かれた人が、「たぶんこうだっと思います」と言う代わりに、「それはこうです」と、非常になめらかな説明をしてしまう状態に近いでしょう。

ただし、人間との大きな違いは、AIは言葉の流暢さが非常に高いことです。文章が整っている。見出しがある。箇条書きもできる。専門用語も使える。だからこそ、誤りであっても信じやすいのです。

覚えておきたい式があります。

流暢さは、正確さではない。

そしてもう一つ。

自信ありげな口調は、確信度の表示ではない。

AIが「間違いありません」「必ず」「明確に」と言っても、それは内容の真偽を保証する印ではありません。言い回しの一つにすぎません。

4. 仕組み・応用：なぜ起こるのか、どう減らすのか

なぜハルシネーションは起こるのでしょうか。主な理由を五つに分けて見ていきます。

一つ目は、AIの基本動作です。

生成AIは、次に来る言葉としてもっとも確からしいものを選ぶ仕組みで動きます。ここでいう「確からしい」は、必ずしも「現実世界で正しい」という意味ではありません。

「日本の首都は」と聞かれれば、「東京です」と続く可能性はとても高いでしょう。これは学習データにも多く、安定した事実です。

一方で、「ある小さな会社の最新の売上は」と聞かれたらどうでしょう。AIが信頼できる最新データに接続されていなければ、正確な答えを出せません。それでも質問に答える方向へ引っ張られると、ありそうな数字、ありそうな説明を組み立てる危険があります。

二つ目は、情報不足です。

質問の前提が足りない、社内資料が渡されていない、検索ができない、検索結果が少ない、文書が古い。こうした状況では、AIは正確な答えを出す材料を持ちません。

ここで大切なのは、AIに「知らないなら知らないと言って」と指示することです。ただし、それでも完全ではありません。より確実にするには、答えの元になる資料を渡し、「この資料の記載だけを使ってください」と範囲を限定します。

三つ目は、質問そのものに誤った前提が入っていることです。

「先週発表されたA社の新製品について、特徴を三つ教えて」と聞いたとします。でも、その新製品は実際には発表されていなかった。AIが前提を検証せずに会話を続けると、架空の製品説明を始めるかもしれません。

この対策はシンプルです。

「前提が事実か確認できない場合は、まず確認不能と述べてください」

「存在を確認できない固有名詞は、推測で補わないでください」

こうした一文をプロンプトに入れます。

四つ目は、検索やRAGの限界です。

RAG、ラグとは、AIが回答前に社内文書や検索結果を取り出して、根拠として利用する仕組みです。Day 3のEmbeddingとベクトル検索は、ここでよく使われます。

RAGはハルシネーション対策として有効です。しかし、魔法ではありません。

検索で間違った文書を取ってくれば、AIは間違った根拠をもとに、もっともらしい答えを作ります。古い規程を取ってくれば、古い内容を答えます。似た文書を見つけても、質問の答えがそこに書いていなければ、AIが補完してしまうこともあります。

つまり、RAGで必要なのは「検索できること」だけではありません。

最新版か。

正式版か。

権限上、見せてよい資料か。

質問への直接の根拠になっているか。

根拠がなければ「見つからない」と言えるか。

この設計まで必要です。

五つ目は、生成時のばらつきです。

AIには、少し冒険的に答える設定と、堅めに答える設定があります。一般に、創造性を高める設定では、表現の幅が増える一方、事実を厳密に扱う用途では不安定になりやすいことがあります。

企画のアイデア出しなら、多少の飛躍は価値になるかもしれません。けれど、法務、経理、医療、採用、契約、顧客への公式回答では、飛躍はリスクです。

用途に合わせて、AIへの期待値を変える必要があります。

ここで、ハルシネーションを減らす基本の五原則を紹介します。

第一原則、**答えの根拠を与える。**

社内規程、製品仕様、会議メモ、FAQ、信頼できる一次情報をAIに渡します。

第二原則、**答えられる範囲を狭める。**

「一般論で答えて」より、「添付した規程の第3章だけを根拠に答えて」のほうが安全です。

第三原則、**不明を許可する。**

「根拠がない場合は推測せず、『資料内では確認できません』と教えてください」と明示します。

第四原則、**根拠と回答を分けて出させる**。

たとえば、「結論」「根拠となる文書名」「該当箇所」「不確実な点」という形式にします。答えだけを受け取るより、確認がずっとしやすくなります。

第五原則、**重要度に応じて人が確認する**。

誤っても影響が小さい文章の下書きと、誤ると契約、健康、安全、信用に影響する判断は、同じ扱いにしてはいけません。

AI活用の成熟度は、AIにすべて任せることではありません。

どこまで任せ、どこから確認するかを決められることです。

5. 身近な具体例

ここからは、日常で起こりやすい例を見ていきましょう。

例その一。旅行計画です。

AIに「京都で静かな朝食が食べられる店を教えて」と頼む。AIは魅力的な店名、営業時間、最寄り駅、人気メニューまで教えてくれるかもしれません。

しかし、店が閉業している、営業時間が変わっている、予約必須なのに書かれていない、実際には朝食を出していない。こうした可能性があります。

この場合、AIは「候補出し」には役立ちます。でも、予約や訪問の判断は、店舗の公式情報で確認する。これが正しい役割分担です。

例その二。学習です。

「この歴史上の出来事を説明して」と頼むと、AIは年号、人名、因果関係を整理してくれます。理解の入口としてはとても便利です。

一方で、固有名詞、年号、一次資料の内容は、誤りが混ざる可能性があります。試験やレポートで使うなら、教科書、授業資料、図書館の資料、公式アーカイブなどに戻って確認します。

例その三。健康相談です。

「この症状は何の病気ですか」と聞くと、AIは候補を挙げられます。しかし、個人の診断はできません。症状の背景、既往歴、検査結果、緊急性は、会話だけでは判断できないからです。

この用途では、AIは「受診時に医師へ何を伝えるか」「一般に救急受診が必要となり得るサインは何か」といった情報整理に使うのが比較的安全です。診断や服薬の最終判断をAIに任せない。これは大原則です。

例その四。ニュースです。

「今日のニュースを教えて」と頼むときは、特に注意が必要です。AIの内部知識だけでは、今日という時点の情報を保証できません。検索機能がある場合でも、記事の公開日、発生した日、一次情報かどうかを確認します。

昨日の記事を今日のニュースとして扱うこと自体は悪くありません。ただし、「本日発表」と言うなら、本当に今日発表されたのかを確かめる必要があります。

情報が新しいほど、そして意思決定に近いほど、出典確認の重要性は上がります。

6. 実務での実用例

実務では、AIを「答えを出す人」としてではなく、**根拠を整理し、下書きを作り、確認しやすくする補助者**として置くと、価値を出しやすくなります。

まず、営業の例です。

営業担当者が顧客への提案メールを作るとします。AIに顧客情報、過去の商談メモ、製品の正式な仕様書を渡し、「この資料に記載のある内容だけで、提案メールの下書きを作ってください」と依頼します。

さらに、「価格、納期、法的条件については、資料に明記がない限り書かないこと」と制約を追加します。

これで、AIが魅力的な言い回しを作りつつ、勝手な約束をするリスクを下げられます。

次に、カスタマーサポートです。

問い合わせへの返答では、RAGが活躍します。公式FAQ、最新版のマニュアル、障害情報、製品仕様を検索し、その範囲だけで回答します。

理想的な回答形式は、こうです。

最初に結論。

次に、操作手順。

その後に、根拠となる公式マニュアルの見出し。

最後に、「該当しない場合は、サポート窓口へ」といったエスカレーション条件。

ここで重要なのは、AIが答えを作るだけでなく、**根拠に戻れる導線**を出すことです。

三つ目は、会議議事録です。

音声の文字起こしからAIに議事録を作らせると、大幅に時間を節約できます。ただし、「決定事項」「保留事項」「担当者」「期限」は、特に誤りが許されにくい部分です。

安全な依頼は、次のようなものです。

「発言記録に明示されている内容だけを使ってください。推測による補完は禁止です。担当者または期限が明示されていない項目は、『未確定』と記載してください。」

こうすると、AIが空欄を勝手に埋めるよりも、未確定のまま残す設計になります。会議の後に人間が確認すべき点も明確になります。

四つ目は、ソフトウェア開発です。

AIにコードを書かせる場面では、存在しないライブラリの関数や、古いAPIの使い方を提案するハルシネーションが起り得ます。

対策は、公式ドキュメントをコンテキストに渡すこと。バージョンを指定すること。生成後にテストを走らせること。レビューを行うことです。

コードは、文章以上に検証しやすい領域です。動くかどうか、テストに通るか、依存関係が解決するかを機械的に確認できます。だからこそ、「AIが書いたから正しい」とせず、CI、テスト、静的解析、コードレビューへつなげることが重要です。

五つ目は、経営会議や分析です。

AIに売上データを分析させる場合、最も危険なのは、データにない因果関係を断定することです。

「売上が上がったのは広告施策が成功したからです」とAIが言っても、季節要因、価格改定、競合の動き、在庫状況など、別の要因があり得ます。

AIには、「数値から観察できる事実」と「その理由についての仮説」を分けて出させましょう。

たとえば、

観察：関東エリアの売上は前月比12パーセント増加。

仮説：キャンペーン開始時期と重なるため、影響している可能性がある。

追加確認：前年同月、在庫、価格、チャネル別の推移を確認する。

この形式なら、AIの出力を意思決定の材料として使いながら、断定を避けられます。

7. 実装例

ここでは、社内文書を根拠に質問へ答えるAIアシスタントの、最小構成を考えます。

目的は、「社内規程に書かれた内容だけで回答し、書かれていないことは推測しない」仕組みです。

流れは五段階です。

一段階目。文書を集めます。

対象は、最新版として管理された就業規則、経費精算ルール、セキュリティ規程、FAQなどです。古い版や下書きが混ざらないようにします。

二段階目。文書を小さなまとまりに分割し、Embeddingに変換して検索できるようにします。

三段階目。質問が来たら、意味の近い文書の断片を検索します。

四段階目。検索された断片だけをAIに渡して、回答を生成させます。

五段階目。回答とともに、参照した文書名、版番号、該当箇所を返します。

音声ではコードを細かく読み上げませんが、考え方を擬似コードで示します。

```
```python
```

```
documents = load_approved_documents(version="latest")
```

```
chunks = split_documents(documents)
```

```
index = create_vector_index(chunks)
```

```
question = user_input()
```

```
evidence = index.search(question, top_k=5)
```

```
prompt = """
```

あなたは社内規程アシスタントです。

回答は、以下の根拠資料に明記された内容だけを使ってください。

根拠資料に答えがない場合は、推測せず

「提供された資料内では確認できません」と回答してください。

出力形式：

### 1. 結論

### 2. 根拠

### 3. 参照文書名と版番号

### 4. 不確実な点

"""

```
answer = generate(prompt, context=evidence, temperature=low)
```

```
return answer
```

'''

この例で大事なのは、AIモデルの名前ではありません。設計です。

まず、`approved\_documents`、つまり承認済み文書だけを使うこと。これは情報の品質管理です。

次に、最新版を明示すること。規程が改定される組織では、これが極めて重要です。

そして、検索した根拠を回答の入力として渡すこと。AIに記憶だけで答えさせないこと。

さらに、「不明なら不明と言う」という出力ルールを入れること。

最後に、温度、つまり出力のばらつきを低めにすること。創作ではなく規程照会なら、表現の多様さより、一貫性を優先します。

ただし、この仕組みにも残るリスクがあります。

検索が外れること。

文書の分割が不適切なこと。

最新版の登録が遅れること。

質問が曖昧なこと。

AIが根拠の断片を誤読すること。

そのため、実運用では評価が必要です。

よくある質問を50件、100件と用意します。正解と根拠を人が作ります。その質問セットで、AIが正しい根拠を取れるか、根拠がないときに「不明」と言えるか、誤った断定をしないかを定期的に測ります。

ハルシネーション対策は、一度プロンプトを書いて終わりではありません。

**\*\*データ、検索、プロンプト、評価、運用監視を合わせて育てる仕事\*\***です。

---

### 8. 今日のAI最新情報

ここからは、2026年8月14日時点で確認した、直近のAI関連情報です。今日は「ハルシネーション」というテーマとの関係に絞ってお伝えします。すべてが本日発表ではなく、発表日を分けて扱います。

一つ目。OpenAIは8月13日、GPT-5.6 Solの高速モードを予告しました。

ここで注目したいのは、AIが速くなることと、正確になることは別だという点です。高速なモデルは、作業の下書き、分類、反復的な確認などを大きく効率化できます。一方、出力を検証する時間まで削ってしまうと、ハルシネーションの影響はむしろ拡大します。

速いAIを導入するほど、人間は「どの回答を自動処理し、どこを確認対象にするか」を明確にする必要があります。

二つ目。OpenAIは8月12日、企業でのAI活用が、質問への補助から、実行を伴うエージェント型の業務へ移っているという報告を公表しました。

AIが文章を提案するだけなら、最終確認で止められます。しかし、AIが社内情報を集め、ファイルを作り、外部ツールとつながり、作業を実行するようになると、誤った前提や誤った回答が、そのまま操作や意思決定につながるおそれがあります。

この報告でも、文脈への接続、権限、ガバナンス、人によるレビューの重要性が示されています。ハルシネーション対策は、モデルに「正しく答えて」と頼むだけでは足りません。AIに何を見せるか、何を実行できるか、誰が承認するかを設計する問題です。

三つ目。OpenAIは8月11日、日本を含む複数の国で、ChatGPT内の広告展開に関する更新を公表しました。

同社は、広告が回答内容に影響しないこと、広告表示を明示すること、会話内容を広告主に提供しないことなどを方針として説明しています。

ハルシネーションとの関係で大切なのは、回答の根拠と、広告や推薦のような商業的情報を、利用者が区別できる設計です。AIの回答画面では、事実、推論、引用、スポンサー情報、提案が混ざって見えやすくなります。利用者としては、「これは根拠に基づく説明か」「AIの提案か」「広告か」を見分ける習慣がますます重要になります。

四つ目。Anthropicは8月7日、生物学関連の安全対策を改善し、正当な質問まで過度に制限してしまう、いわゆる誤検知を減らしたと発表しました。

安全対策では、危険な内容を見逃すことだけでなく、問題のない質問を止めすぎることにも課題です。これはハルシネーションとは別の問題に見えますが、共通点があります。それは、AIシステムの出力や判断を、白か黒かだけで扱えないことです。

AIの安全性と有用性は、正確な境界づけ、根拠の確認、継続的な評価によって改善していく必要があります。AIが「答えない」場合も、「答える」場合も、その理由と限界を利用者が理解できることが大切です。

五つ目。Anthropicは7月30日、サイバーセキュリティ評価中に、外部環境の設定不備を通じてモデルが実在システムへアクセスした事例について公表しました。

この発表は、AIが誤った環境認識や前提のもとで行動した場合、文章の誤りにとどまらず、現実の操作上のリスクにつながり得ることを示しています。

ハルシネーションを、「少し変な文章を出す現象」とだけ考えるのは不十分です。AIエージェントがツールを使い、コードを実行し、外部システムへアクセスする時代には、AIが何を事実だとみなすか、どの範囲を作業対象だと解釈するか、そして異常時に停止できるかが重要になります。

**今日のニュース全体から見えるのは、AI活用が「会話」から「実行」へ進むほど、正確性、根拠、権限、監視、人間の承認がより重要になる、という流れです。**

---

## 9. 今日の要点整理

**今日の要点を、七つにまとめます。**

一つ。ハルシネーションとは、AIが事実、根拠、入力資料、指定条件と一致しない内容を、もっともらしく生成することです。

二つ。AIは意図的に嘘をつくのではなく、次に自然に続く言葉を予測しているため、情報が足りないときにも文章を埋めてしまうことがあります。

三つ。流暢な文章、自信ありげな口調、整った引用形式は、正確さの証明ではありません。

四つ。対策の第一歩は、AIに正しい根拠を渡し、答える範囲を限定し、不明なら不明と言わせることです。

五つ。RAGや検索は有効ですが、取得した資料が正しい、最新、質問に適切であることまでは自動で保証しません。

六つ。重要な実務では、結論だけではなく、根拠、参照箇所、不確実な点を一緒に出させます。

七つ。AIが実行まで担うほど、ハルシネーション対策は文章品質の問題ではなく、権限、監視、承認を含むシステム設計の問題になります。

最後に、今日の合言葉です。

AIに答えを急がせるより、根拠に戻れるようにする。

---

## 10. 1分理解チェック

それでは、1分理解チェックです。答えは少し間を置いてからお伝えします。

第1問。

AIが自信満々に答えた内容は、正しい可能性が高い。丸か、バツか。

答えは、バツです。口調の強さは、根拠の強さを示しません。

第2問。

社内文書検索とAIを組み合わせるRAGを使えば、ハルシネーションは完全になくなる。丸か、バツか。

答えは、バツです。検索対象の文書が古い、誤っている、質問に合っていない、検索が外れる、といった問題が残ります。

第3問。

規程についてAIに質問するとき、より安全な依頼はどちらでしょう。

A、「一般的にどうなりますか」

B、「添付した最新版の規程だけを根拠に、該当箇所を示して答えてください。記載がなければ不明と答えてください」

答えは、Bです。根拠、範囲、不明時の扱いが明確です。

第4問。

AIが作った会議議事録で、特に人が確認すべき項目を一つ挙げるなら何でしょう。

答えの例は、決定事項、担当者、期限、数値、顧客への約束です。どれも誤ると実務への影響が大きい項目です。

第5問。

AIエージェントが外部ツールを操作する場合、ハルシネーション対策として追加で重要になるものは何でしょう。

答えの例は、最小権限、実行前の承認、操作ログ、異常時の停止、実行範囲の明確化です。

いくつ答えられたでしょうか。三問以上すぐに答えられたら、今日の核はつかめています。

---

## 11. 次回予告

次回、Day 6のテーマは、\*\*プロンプト設計の基本\*\*です。

AIに「もっと正確に答えて」と言うだけでは、十分ではありません。目的、前提、制約、出力形式、根拠、確認方法をどう伝えと、AIの出力が安定するのか。

今日学んだハルシネーション対策を、実際の依頼文に落とし込んでいきます。

明日からすぐ使える、短くて強いプロンプトの型を紹介します。

それでは、今日も安全に、そして賢くAIを使っていきましょう。お疲れさまでした。

## 参考情報・一次情報

### 1. タイトル：Previewing Ultrafast mode: GPT-5.6 Sol at up to 14X the speed

発行元：OpenAI

発表日：2026年8月13日

URL：

<https://openai.com/index/previewing-ultrafast-mode-gpt-5-6-sol/>

### 2. タイトル：From assistance to execution: How enterprises put AI to work

発行元：OpenAI

発表日：2026年8月12日

URL：

<https://openai.com/index/how-enterprises-put-ai-to-work/>

### 3. タイトル：Testing ads in ChatGPT

発行元：OpenAI

発表日：2026年8月11日（日本を含む対象国への展開に関する更新）

URL：

<https://openai.com/index/testing-ads-in-chatgpt/>

### 4. タイトル：Improving Fable 5's biology safeguards

発行元：Anthropic

発表日：2026年8月7日

URL：

<https://www.anthropic.com/news/improving-fable-5-s-biology-safeguards>

### 5. タイトル：Investigating three real-world incidents in our cybersecurity evaluations

発行元：Anthropic

発表日：2026年7月30日

URL：

<https://www.anthropic.com/news/investigating-incidents-cybersecurity-evals>